云连接车辆自适应多分支目标检测与重构方法

Abhra Majumder、Nirmalya Ghosh *IEEE会员*，Anirban Mukherjee *IEEE高级会员*，以及Siddhartha Mukhopadhyay

***摘要*——本文提出了一种专为联网车辆设计的基于摄像头的多分支目标检测架构。该系统采用共享特征提取主干网络与多个专用检测分支相结合的设计方案，各分支分别负责识别特定目标类别（如行人、车辆、交通信号灯等）。通过云端服务器推荐的动态分支选择机制，车辆可根据实时需求灵活启停检测分支，从而在多变的交通环境条件下实现自适应感知。在该框架中，联网车辆会定期向云端服务器传输采样图像帧。云端服务器对图像帧进行分析，识别最具相关性的目标类别，并据此向目标车辆发出指令。这种基于云计算的策略能够在资源受限的嵌入式平台上实现轻量级且自适应的物体检测，同时保持高检测精度。实验结果表明，与双并行检测器相比，该方案每秒浮点运算量减少38.2%，内存消耗降低43.4%，且仍保持业界领先的平均精度水平。所提出的架构显著提升了自主感知系统的可扩展性、计算效率及适应性。**

***索引术语*——联网自动驾驶汽车、多分支目标检测、云辅助感知、物联网。**

I. 引言

摄像头、雷达、激光雷达（LiDAR）和超声波传感器因具备易获取性、成本优势及耐用性，已广泛应用于汽车环境感知领域。研究人员正致力于借助深度学习技术[1]–[3]，将车辆运动预测任务应用于周边车辆检测场景。

车辆视觉感知的第一步是检测和分类多种物体，如行人、车辆、障碍物等。该功能可确保（半）自动驾驶系统的安全性和效率[4]。在能见度较差的条件下，语义分割和目标检测性能可能下降。热成像技术可解决深度数据的某些局限性[5]。

传统汽车应用中的目标检测方法存在以下根本性局限性：

- 基于预设对象类别的批量分类检测系统[6]–[8]，若未经大量再训练，将无法适应新的环境场景。
- 增量学习方法[9][10] 存在灾难性遗忘现象，即学习新物体类别会降低先前已学习类别的表现。
- 车辆中资源受限的边缘计算平台限制了高计算成本检测模型的部署[11]。[12].

在开发能够根据上下文需求动态调整检测能力、同时保持现有数据集上计算效率与分类准确性的目标检测框架时，存在一个技术挑战。以联网车辆从高速公路转向城市环境为例：检测需求从最初主要关注车辆和路标，逐渐扩展到需要识别行人、路面、骑行者、交通信号灯等各类相关物体。当前系统要么持续保持所有检测功能（导致计算资源浪费），要么在场景切换时需要人工重新配置。因此，场景理解与情境感知能力显得尤为重要[13]。[14].

为解决这一问题，研究问题表述如下：
一个具有参数的对象检测器$f_{\theta}\boldsymbol{\theta}$在对象类别$C$上训练后，需要动态修改以检测修改后的类别集合，$C^{*}=(C\setminus C-)\cup C^{+}$。其中，$C^{+}$表示新对象类别集合（需包含），$C^{-}$表示现有对象类别集合（需排除）。该适应过程必须满足以下约束条件：

性能保持：保留类别的检测准确率（$C\setminus C-$）不得显著下降。**计算效率**：资源使用量应随活跃检测分支数量而非可用总类别数进行合理扩展。
动态重构：系统必须支持在运行时添加/移除检测功能，且无需离线重新训练。

本研究结构安排如下：第一节介绍后，第二节对既往研究进行简要综述。所提出的方法学已在第III节和第IV节中描述。随后，第V节阐述了各项实验结果。最后，第VI节提供了研究结论及未来研究方向。

本研究由印度理工学院卡拉格普尔分校AI4ICPS I Hub基金会资助（项目编号TRP3RDTR011，资助日期：2024年2月21日），并在印度西孟加拉邦卡拉格普尔印度理工学院先进交通卓越中心开展。（*通讯作者：Anirban Mukherjee*。）

作者隶属于印度理工学院卡拉格普尔分校电气工程系，地址：印度西孟加拉邦卡拉格普尔市，邮编721302（电子邮箱：abhra.majumder01@gmail.com、nirmalya@ee.iitkgp.ac.in、manir ban@ieee.org 及 smukh@ee.iitkgp.ac.in）。

II. 相关工作

A. 批次分类检测器

批量类别检测器（BCDs）或传统检测器经过训练可检测固定对象类别集合[15]。尽管BCDs并未直接解决检测$C \cup C^+$这一问题，但其架构常被用作类别增量检测器的骨干网络。传统目标检测器可大致分为两类：(i)单阶段检测器与（ii）双阶段检测器。

在单阶段检测器中，将定位和分类任务整合到一个端到端网络中，该网络可直接预测边界框。典型示例包括单次检测器（SSD）[16]和YOLO系列检测器[17]、[18]，这些方法能提供（近）实时检测并保持具有竞争力的准确率。

在两阶段检测器中，第一阶段用于识别感兴趣区域（ROIs），即潜在目标位置，第二阶段则对ROIs应用分类网络以实现目标识别。基于区域的卷积神经网络 RCNN [7]、Fast R-CNN[8]和Faster R-CNN[19]是最受欢迎的两阶段边界条件检测器（BCDs）之一。

B. 增量类检测器

增量类别检测器通过采用类别增量学习（CIL）[20]部分解决了该问题。在此方法中，参数集θ被更新为θ^*，使得模型能够同时检测先前已学习的类别和新对象类别C^+。然而，简单的微调常会导致灾难性遗忘。为缓解此问题，知识蒸馏[21]和元学习[22]等技术被广泛采用。**知识蒸馏**：知识蒸馏[21]传统上通过最小化输出间的Kullback-Leibler散度[23]，将知识从大型教师模型传递至小型学生模型。在CIL框架中，该散度降低机制被有效利用。多项研究[24]–[27]采用知识蒸馏方法，将旧检测器作为教师，克隆分支作为学生。随后该学生被训练用于检测C^+以及C。例如，[26]对C和C^+均施加余弦归一化以缓解类别不平衡问题。在[28]中，仅对C更新前K个神经元，而对C^+训练新神经元。然而该方法未充分利用网络容量，因为部分固定用于C的神经元仍需针对C^+进行微调。

元学习：元学习将从数据集中学习视为一项任务，并利用跨任务经验快速适应新任务。例如，[9], [10] 在Faster R-CNN框架[19]中采用元学习方法以适应新类别。具体而言，[9] 通过插入变形层对区域提议网络进行修改以适应新类别，同时[10]冻结基于大规模类别预训练的特征提取器，并采用少样本元学习仅更新目标定位模块。

C. 独立并行探测器

独立并行探测器（IPDs）可同时运行多个探测器。例如，[29] 采用双并行YOLO架构模型，一个用于C，另一个用于C^+，并附上检测结果。

D. 局限性

为识别研究空白，需沿以下维度对既往研究进行参数化比较。

新类别包含：动态检测器的主要要求是能够同时识别C和C^+。然而，BCD本质上仅限于固定类别，且不支持新类别包含。

并行分支：同时为C和C^+维护单一网络会降低准确性，因为C^+的权重更新常会损害C的性能。因此，平行分支法常被采用[27]。[30], [31]例如，[30] 采用Faster RCNN 处理C，并使用FewX-Net处理C^+，随后通过融合层合并输出。类似地，[31] 训练两个独立分支并通过深度整合网络统一其输出结果。文献[29]中的作者识别出C与C^+之间的混淆类别，随后并行训练针对这些类别的专用检测器。然而此类方法存在局限性：(i)两个分支必须进行端到端训练，(ii)参数未共享导致内存占用过高。通用特征提取器可缓解这些问题[10]。

通用特征提取器：多项研究[32]-[35]采用预训练的通用特征提取器（CFE），该模型由检测器的初始层构成，用于提取所有物体类别共有的特征。研究者仅对同一检测器的最终类别特定检测层进行修改以适配C^+。例如，[35] 使用一个在超类集$C^{\sim}$上预训练的 CFE，其中$C^{\sim}$、C、C^+。

类别重叠考量：除[35]外，大多数现有方法均忽视类别重叠情况，即$C' = C \cap C^+$（该情形在实践中十分常见）。文献[35]通过采用分数融合模块来协调重叠预测结果，从而解决了这一问题。

类别排除：少数研究[30]，[31], [34]–[36] 将并行分支与CFE 相结合，但均未考虑从C中排除类子集C^-，C以仅保留特定场景所需的对象类C（即$C = C/C^-$），这对于边缘感知等资源受限应用至关重要。

在线分支重构：据作者所知，目前尚未发现采用基于服务器推荐的动态二维目标检测分支选择方法的相关研究。该比较分析结果汇总于表I中。

E. 建议方法

本文提出的方案概述如下：

i. **自适应多分支目标检测器（AMOD）**：本文提出了一种检测架构，能够动态添加相关分支并移除非目标分支。该架构的框图如图1所示。该架构采用 CFE 生成共享低级特征，并将这些特征输入并行的类别特定检测分支（CDBs）。类别重叠

表I：相关文献综述

方法学	NCI[a]	PB[b]	CFE[c]	COD[d]	CE[e]	OBR[f]
RCNN [7]	×	-	-	-	×	×
快速 RCNN [8]	×	-	-	-	×	×
更快的 RCNN [19]	×	-	-	-	×	×
SSD [16]	×	-	-	-	×	×
YOLOv1 [17]	×	-	-	-	×	×
YOLOv3 [18]	×	-	-	-	×	×
Hou等[26]	✓	×	×	×	×	×
Yang等[27]	✓	×	×	×	×	×
K. Joseph等[9]	✓	×	×	×	×	×
李等人[28]	✓	×	×	×	×	×
Cheng等[10]	✓	×	✓	×	×	×
Hao等[24]	✓	×	✓	×	×	×
Y. Wu等[32]	✓	×	✓	×	×	×
Zhao等[33]	✓	×	✓	×	×	×
iCARL [37]	✓	×	✓	×	×	×
Castro等[34]	✓	✓	✓	×	×	×
POD [36]	✓	✓	✓	×	×	×
Tambwekar等[30]	✓	✓	×	✓	×	×
Zhang等[31]	✓	✓	×	×	×	×
T. Wu等[35]	✓	✓	✓	✓	×	×
Gkaragkanis等[29]	✓	✓	×	×	✓	×
建议	✓	✓	✓	✓	✓	✓

[a] NCI：新类别纳入

[b] PB：并行分支

[c] CFE：通用特征提取器

[d] COD：类别重叠数据集

[e] CE：类排除

[f] OBR :在线分行重构建议

过滤器（共价有机框架）通过抑制置信度分数较低的边界框来解决重复检测问题，当多个分支预测同一对象属于不同类别时。

ii. **基于云的 AMOD 框架：**为在 AMOD 中决定候选分支的增删方案，本文提出了一种基于云的 AMOD 框架。该框架包含两个核心组件：

a. 云组件：基于云的分行推荐系统（CBRS）

b. 边缘组件：车辆检测系统（VDS）。

CBRS 确定从自车获取的特定帧所需的目标类别（即检测分支）。 VDS 根据 CBRS 的建议，对运行于自车边缘设备中的 AMOD 进行修改。

所提出的基于云的 AMOD 框架的UML组件图如图2所示，展示了 CBRS 与 VDS 之间的交互关系。 CBRS 通过云服务处理数据集管理、训练及分支推荐，而 VDS 则利用选定分支进行车载检测，并通过本地用户界面（LUI）支持用户交互。UML序列图详见[38]。

虽然基于CIL的方法通常会导致整体mAP下降，但所提出的方法保留了预训练特征提取器，并为C和C^+训练独立的检测分支。随后应用类别重叠滤波器以消除

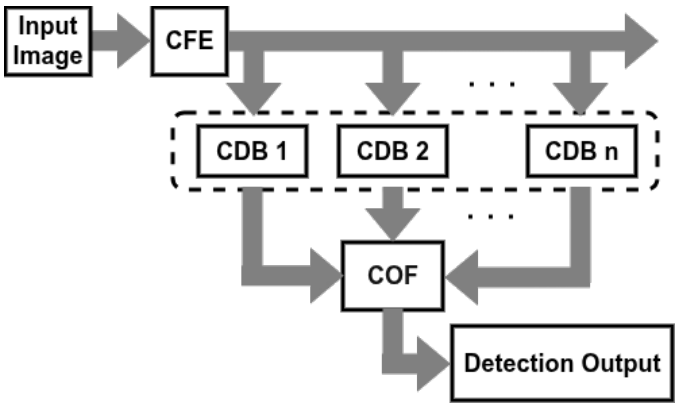

图1：自适应多分支目标检测器

跨分支检测中的重复现象。由于各分支独立运行，既可实现包含操作（C^+），也可实现排除操作（C-），且不会影响平均准确率（mAP）。

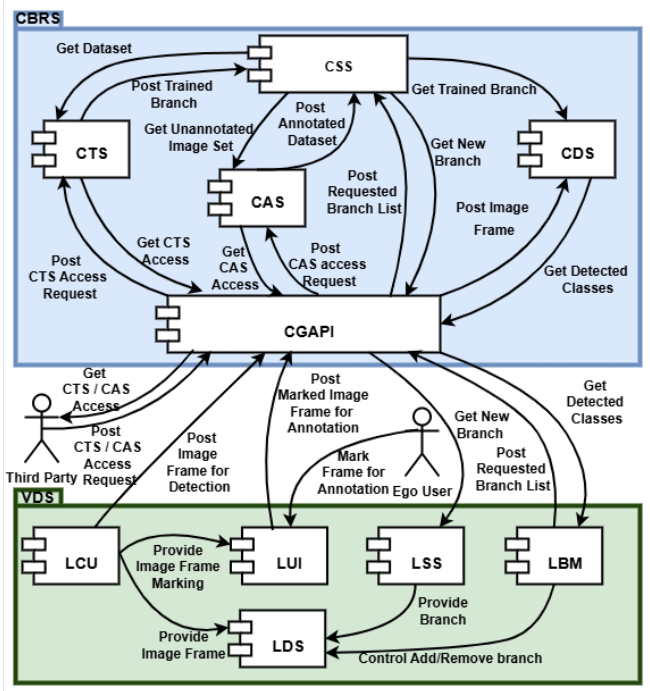

图2：基于云的 AMOD UML组件图。

F. 捐款

根据表I所示的比较分析，本研究的主要贡献如下：

i. **共享多分支架构：**该架构具有通用特征提取器和并行检测分支的共同特征，经验证可在保持准确率的同时实现动态重构。

ii. **云边协同系统：**该系统是一种在线决策系统，其中云分析指导边缘设备中检测器的分支选择。

iii. **实验验证的效率提升：**对 NVIDIA Jetson Orin Nano的实验表明 AMOD

与两个独立并行检测器（IPDx2）相比，其推理速度提升9%，在工作站级硬件上实现4.2%的加速比（详见表VI）。

iv. **效率分析：**计算模型显示该架构可实现38.2%的浮点运算量（FLOP）降低
与独立并行检测器相比，内存节省率达43.4%（详见表VIII）。

在基准数据集[39]上对三种竞争性基线方法进行了全面评估，并观察到了所提出的并行分支技术的有效性。

III. 主要工作：AMOD

AMOD 构成了针对第I节所定义问题的解决方案核心。该方案采用 CFE 从输入图像中提取跨对象类别的低级特征，随后将这些特征传递至如图1所示的CDBs。

A. 组件

CFE：该方法从输入图像中提取低级空间特征，例如水平线、垂直线、角点等。该 CFE 在一组类别$C^{\sim}$上进行训练，该集合是对象类别C和C^{+}的超集，即$C^{\sim}$，$(C^{\sim} \cup C^{+})$。因此它可以用于检测属于$(C^{\sim} \cup C^{+})$的所有对象类别。这消除了为检测属于集合C或C^{+}的对象而需要完全独立检测器的需求，从而降低了内存开销。本研究中采用 Darknet-53 网络 [17]（YOLO 的 53 层主干网络）作为 CFE 。**CDB：**检测分支基于YOLOv3架构[18]，其通过特征金字塔网络在三个尺度上生成预测结果，以实现对小型、中型和大型对象的有效检测。针对特定对象类别调优的独立特征金字塔并行应用于不同对象类别，且彼此间不共享参数。并行分支结构的优势包括：(i) 防止先前学习类别发生灾难性遗忘；(ii) 能快速纳入或排除预训练分支，以适应特定检测需求。

共价有机框架：由于每个检测分支都在独立数据集上进行训练，不同分支之间可能存在重叠类别，这会导致对同一对象的多次检测。为此引入了一种基于相似度分数的过滤机制来解决这一问题。检测到的边界框b_i与b_j之间的相似度分数S（对应预测类别C_i和C_j）定义为：

$$S(b_i, b_j) = \delta(C_i, C_j) \cdot IoU(b_i, b_j), \tag{1}$$

其中 $\mu(C_i, Cj)$ 是由克罗内克 μ 函数给出的

$$\delta(C_i, C_j) = \begin{cases} 1, & \text{if } C_i = C_j, \\ 0, & \text{otherwise} \end{cases} \tag{2}$$

b_i与b_j之间的交并比（IoU）为

$$IoU(b_i, b_j) = \frac{b_i \cap b_j}{b_i \cup b_j}. \tag{3}$$

当$b_i = b_j$时，得分S达到最大值。若$S > S_t$（相似度阈值），则两个边界框均被考虑表示同一对象。在此情况下，置信度较低的边界框将被舍弃。

检测器框架的操作流程如算法1所示。

算法1基于类别重叠滤波器的并行分支目标检测

$x(I_i) = f_{\theta(darknet)}(I_i)$.
对于 $f_{\theta(YOLO)i}(\cdot)$，$F_{\theta(YOLO)}$ **do**
  $b_{c_i \in C \cup C^+} \in B_{C \cup C^+} = f_{\theta(YOLO)i}(x(I_i))$.
对于 b_{c_i}，$C \cup C^+$，$BC_{\cup C^+}$ **do**
  计算$S(b_i, bj)$
  如果$S(b_i, bj) \leq S_t$**则**
    继续
  其他的
    $B'_{C \cup C^+} = B_{C \cup C^+} \setminus \{\arg\min_{b \in \{b_i, b_j\}} \mathrm{Conf}(b)\}$
输出：$B'_{C \cup C^+}$

此处，输入图像I_i被输入到 CFE $f_{\theta(darkent)}(\cdot)$中，以提取低级空间特征$x(\cdot)$。随后将其输入每个 CDB $f_{\theta(YOLO)i}(\cdot)$，$F_{\theta(YOLO)}$以检测特定对象类别集合c_i，$(C^{\sim} \cup C^{+})$。每个检测分支的输出是一组边界框b_{c_i}，$B_{C \cup C^+}$，其中$B_{C \cup C^+}$是所有检测分支中检测到的边界框集合。此处$F_{\theta(YOLO)}$是检测$(C^{\sim} \cup C^{+})$中所有类别所需的全部可能分支集合。理想情况下，每个分支应检测唯一类别集合，即c_i, c_j，$(C^{\sim} \cup C^{+})$且$c_i \cap c_j = \varnothing$。实际应用中，各分支使用独立数据集训练，可能存在共同对象类别集合c'，$(C^{\sim} \cup C^{+})$。因此，多个分支可能为同一对象生成边界框。共价有机框架过滤器会检查所有检测到的边界框集合中元素之间的相似度得分S（b_i，bj），即$B_{C \cup C^+}$。若相似度得分超过阈值S_t，则两个边界框表示相同对象。因此，置信度得分较低的边界框会被舍弃。需要说明的是，$B_{C \cup C^+}$中的元素已通过非最大值抑制步骤，该步骤会从各自分支中移除相同对象的重叠边界框。因此可以假设，来自检测分支的所有边界框均代表唯一对象，而$B_{C \cup C^+}$中的任何重叠均意味着同一对象被多个分支检测到。为消除这些重叠，仅需计算属于同一对象类别的边界框之间的IoU值即可。

B. 探测器损失函数

为优化类别特异性检测分支，本文采用复合损失函数，方法参照[18]。该模型由三个组成部分构成：(i)边界框损失、(ii)置信度损失以及(iii)分类损失。

边界框损失：原始YOLOv3实现[18]采用平方和误差进行边界框回归，后续研究[40]表明该方法对IoU优化效果欠佳。根据[41]，本文采用广义交并比（GIoU）：

$$L_{GIoU} = 1 - GIoU, \tag{4}$$

在哪里

$$GIoU(\hat{b}, b^*) = IoU(\hat{b}, b^*) - \frac{|C(\hat{b}, b^*) \setminus (\hat{b} \cup b^*)|}{|C|}, \quad (5)$$

其中ˆb表示预测边界框，b^*表示真实边界框，C(ˆb，b^*)表示同时覆盖ˆb和b^*的最小包围框，$|\cdot|$表示集合基数。**置信度损失**：自VOC 2007数据集以来，[39]存在严重失衡，表现为局灶性缺损[42]该方法旨在弱化简单案例的权重，使训练重点聚焦于更复杂的病例。焦点损失定义如下：

$$FL\,(p_t) = -(1 - pt)^{\gamma} \log\,(pt), \quad (6)$$

其中p_t。[0,1]表示真实类别的预测置信度分数，$\check{y}$ >0是用于快速衰减高置信度类别损失分量的可调参数。**分类损失**：采用类别二元交叉熵损失而非分类交叉熵[18]，这消除了对softmax层的需求，从而在提升训练效率的同时降低计算开销。

C. 探测器分支的最佳数量

尽管检测分支数量的增加会提升系统的可重构性，但也会导致更高的计算复杂度。对于资源受限的边缘设备而言，确定最佳分支数量至关重要。为此，我们采用基于综合评分的分支选择策略，该评分由可重构性评分S_R（B）与计算复杂度评分S_C（B）的凸组合构成。

$$S(B) = w_1 S_R(B) + w_2 S_C(B) \quad (7)$$

其中w_1, w_2。[0,1] 为权重且$w_1 + w_2$= 1。**重构能力评分**：该指标用于量化CDBs的重构灵活性。对于每个对象类别c_i。($C_{\breve{}}$ $C+$)，若存在分支，则通过增减分支即可最灵活地重构 AMOD，且不会影响其他类别的检测能力。此时重构能力达到最大值；反之，当所有对象类别仅存在单一分支时，重构能力为最小值。因此，当每个 CDB 仅包含一个类别时，分支数量B的可重构性$R(B)$定义为可用分支数B与最大分支数B_{Max}的比值。尽管这表明可重构性B/B_{Max}会随分支数量增加而线性增长，但为每个对象类别单独配置CDB并不现实。实际上，核心分支C/C^-中的对象类别数量$|C/C^-|$远大于新分支C^+中的数量，即$|C/C^-|_{\breve{}}|C^+|$。此外，在C^+中为每个对象类别单独添加分支会增加（不必要的）实现复杂度。因此，为通过降低分支数量权重来减少CDB数量，提出了可重构性评分。该评分采用对数尺度定义如下：

$$S_R(B) = \frac{\log(B+1)}{\log(B_{\max}+1)}. \quad (8)$$

计算复杂度评分：随着分支数量的增加，B，提高了可重构性，$R(B)$

对于该模型而言，它还会增加计算复杂度$C(B)$，因为每个分支都需要单独执行。在检测器的推理过程中，$C(B)$主要取决于

i. 卷积运算
ii. 激活函数运算
iii. 边界框坐标转换至实际坐标。因此，检测分支的计算复杂度是各层级不同计算复杂度的累加结果。例如，若某检测分支包含M个卷积层（由卷积运算与激活函数操作组合而成）和N个预测层（即输出层，由激活函数与变换函数组合而成），则整个检测分支的计算复杂度可表示为：

$$C(B) = \sum_{i=1}^{M} \{(C(CL_i) + C(AL_i)\} + \sum_{j=1}^{N} \{C(AL_j) + C(TL_j)\} \quad (9)$$

其中$C(CLi)$和$C(ALj)$分别表示卷积操作后接激活操作的计算复杂度i th卷积层。$C(TLj)$ 表示变换操作的计算成本。详细说明可参见 GitHub 仓库 [38]。

需要特别说明的是，若采用N个IPD替代所提出的带CFE 多分支检测器，总计算复杂度将为

$$C_T = \sum_{i=1}^{N} (C(F) + C(B_i)) \quad (10)$$

与...相比

$$C_T^* = C(F) + \sum_{i=1}^{N} C(B_i) \quad (11)$$

对于具有通用特征提取器的检测器而言，因此

$$C_T = C_T^* + (N-1)C(F) \quad (12)$$

其中，$C(F)$ 表示检测器中 CFE 部分的计算复杂度。

为在选择最优分支数量时保持较低计算复杂度，我们采用计算复杂度评分S_C（B）。其定义如下：

$$S_C(B) = 1 - \frac{C(B) - C_{min}}{C_{max} - C_{min}} \quad (13)$$

其中$C(B)$表示分支数为B时的计算复杂度，C_{min}和C_{max}分别表示给定类别数量时可能存在的最小和最大分支数对应的计算复杂度。**最优性得分**：具有最大总体得分S（B）的分支数$B^\star$，如（7）所示，是

$$B^\star = \arg\max_B S(B) \quad (14)$$

为确保实际应用可行性，最终需满足最大可用内存的硬件限制条件，即

$$B^{\star} = \arg\max_{B} S(B) \text{ 且满足} M(B) \leq M_{Max} \quad (15)$$

其中M（B）和M_{Max}分别表示执行具有B个分支的模型所需的内存以及目标硬件中可用的最大内存。

这确保了系统在保持灵活性的同时，将计算复杂度和内存使用量控制在目标设备可接受的范围内。

IV. 主要工作：基于云的 AMOD

选择合适的分支组合是所提出系统的一个重要方面。其目的是确保对于给定场景中存在的每个对象类c，在推荐的检测分支集合B_{rec}中存在能够检测该对象类的检测分支B，即

$$\forall c。\ (C/C\text{-})_{\text{。}}\ C^{+}；存在 B。\ B_{rec}：c\ 属于类\ (B)\ (16)$$

为实现这一目标，本文提出了一种基于云的 AMOD 框架。该系统包含两个部分：(i)车辆检测系统（VDS）和基于云的分店推荐系统（CBRS）。

A. VDS

该 VDS 的配置包含以下组成部分：

i. **本地摄像头单元（LCU）**：作为自动驾驶车辆的核心传感器，它持续向本地检测服务传输图像帧流，并将数据同步至 CBRS 系统用于分支决策推荐。

ii. **本地检测服务（LDS）**：该处理单元根据需求运行 AMOD，采用较少的检测器分支结构。

iii. **本地存储服务（LSS）**：所有预训练检测器分支权重（模型参数）均存储于此。 AMOD 首先在本地存储单元（LSU）中查找特定场景对应的分支权重。若未找到，则从 CBRS 服务器下载 AMOD 。

iv. **地方分行经理（LBM）**：负责根据 CBRS 建议对 AMOD 分行进行调整。

v. **本地用户界面（LUI）**：当 CBRS 服务器不可用时，用于手动选择分支。

VDS 组件的工作方法论总结于算法2中。在时间t= 0时刻，系统通过 LBM 初始化LDS中的 AMOD（基于默认检测分支）。随后LDS开始从 LCU 获取图像帧I_t，并基于默认检测分支进行目标检测。若自车已连接 CBRS 系统，则会定期向 CBRS 发送图像帧。 CBRS 系统会检测图像帧中所有目标，并返回用于检测目标的分支列表。当 LBM 接收到该列表后，会对比当前运行的检测分支与 CBRS 发送列表之间的差异。若发现差异，系统将检查推荐分支权重是否已完整存储于 LSS 中。若未找到，则 LBM 向 CBRS 发送下载请求，获取缺失的分支并存储在 LSS 中。新分支B_{new}被添加至 AMOD，系统随即开始检测新的对象类边界框。

若ego车辆未连接 CBRS，也可通过LUI界面手动在 LSS 中增减分支。

算法2 VDS

AMOD ←初始化 (*BdLeSfaSult*)
虽然并非帧结束（LCU）**会**
I_t←获取图像（LCU）　　图片来自 LCU
如果CBRS 。状态=在线**则**
　　若t mod T_s=0**则**
　　发送 (I_t→ CBRS)
　　分支ID列表←来自 CBRS
　　如果分支ID列表≠ B_{LSS}分支ID列表**然后**
　　如果存在 (LSS，分支 ID)**则**
　　AMOD ← ld br (LSS，分支 ID)
　　其他的
　　B_{new} ← dnld br (CBRS，branch id)
　　存储（B_{new} → LSS）
　　AMOD ← B_{new}
　　D_t ← AMOD detect (*It*)　输出
否则
分支 ID ← LUI.select()
AMOD ←加载分支（LSS，分支ID）
　$t \leftarrow t+1$
输出：连续检测结果D_t，检测分支动态更新

ld br= 加载分支，**dnld br**= 下载分支

B. 通播接收台

与 VDS 类似，该 CBRS 包含以下组成部分。

i. **云网关API（CGAPI）**：它作为车辆边缘计算系统与云端服务之间的通信桥梁。

ii. **云检测服务（CDS）**：该系统通过分析场景数据，并利用云计算资源生成分支推荐方案。

iii. **云存储服务（CSS）**：该服务将检测模型、训练数据集、标注图像及系统元数据存储于云端。

iv. **云训练服务（CTS）**：该服务通过收集的数据和用户标注对检测模型分支进行训练与更新。

v. **云标注服务（CAS）**：该服务可处理并验证图像标注数据（包括自动化生成与人工标注），用于模型训练。

他们的联合工作方法总结于算法3中。该 CGAPI 首先初始化自身状态，持续等待主控车辆的请求。对于CDS系统，当接收到输入图像时，会检测画面中的物体并生成至少包含一个物体的检测分支列表，随后将该列表返回给请求车辆。若请求车辆再次要求提供分支信息，则从CSS系统中调取相应数据并反馈。对于CAS系统，

算法3 CBRS

初始化G 云网关 API
当从车辆**do**接收到请求(It)时
    ($它$)$\leftarrow G\ recv()$
    $G.forward(\mathcal{D}，(I_t))$ D: 云检测服务
    $B_{rec} \leftarrow D(它)$ 场景分析→分支集
    $\mathcal{G}.send(B_{rec})$
    $\mathcal{S}.store(它，Brec)$ S：云存储服务
    如果注释A_t可用**时**
        $A_t \leftarrow A(它)$ A：注释服务
        $\mathcal{S}.store$（在）
    如果训练触发θ= 1**则**
        $D \leftarrow \mathcal{S}.retrieve(\mathcal{D}_{train}, \mathcal{A}_{set})$
        $B_{new} \leftarrow \mathcal{T}(D)$ T：培训服务
        $\mathcal{S}.update(B_{new})$
        $\mathcal{G}.notify(B_{new})$

系统会收集用户标注数据，并在验证完成后将其存储至CTS的CSS文件中。当触发CTS机制时，系统将根据第三方用户指令从CSS获取数据集，训练新分支B_{new}，并将其存储至CSS供CDS后续调用。

V. 实验与结果

所提出的方法学分为两个主要部分以进行实验验证。

i. **检测器模型测试（DMT）：**该测试用于评估所提出的检测器模型的准确性和速度性能。
ii. **自动分支推荐系统测试（ABRST）：**该测试针对推荐服务器检测器在不同天气条件下的性能表现。

A. *DMT*

为评估所提出的多分支检测器的有效性，已选定基准数据集和评估矩阵。进行以下测试：

i. DMT-I：模型准确性比较测试
ii. DMT-II： CBRS 推断测试
iii. DMT-III： VDS 推断测试
iv. DMT-IV：模型复杂性测试

*1) **数据集与评估矩阵选择：***为比较为评估所提方法学与其他方法的性能，采用文献[43]中所述的标准评估技术。评估工作采用Pascal VOC 2007数据集[39]进行，该数据集包含9,963幅图像及24,640个标注数据，涵盖20类物体。数据集被均分为训练集和测试集，测试集仅在评估阶段开放访问且不进行模型权重更新。计算平均精度（mAP@50）时采用IoU阈值[44]，将边界框判定为真阳性时的平均精度阈值设为0.5。最后通过每秒千兆浮点运算量（GFLOPS）和兆字节（MB）内存消耗量来评估最优分支数量。

*2) **DMT-I：模型准确性比较测试：***男性如第3节所述， CFE 和CDBs是分别进行训练的。对于CFE，采用了一个预训练模型。[17]基于ImageNet数据集训练[45]，用于训练 CDB 。训练过程中采用Pascal VOC数据集[39]。

不同的分支训练被视为不同的任务T_t，在任意时间点$t \in \mathbf{R}$，其中训练过程中向学习者呈现一个子集C_t，C。任务T_t的数据D_t是通过选择数据集中的所有图像生成的。然而，不属于C_t的类别实例会被标记为其他类别。

在Pascal VOC数据集上，所有类别均按字母顺序排列，并通过分组方式创建多个任务。本实验参照[9]方法，按难度递减顺序设计了四种场景，每次训练最多使用20个类别。具体场景如下：

1) **场景-1（S1）：**T_1包含最初的15个类别，接下来的五个连续任务（$T_2 \cdots T_6$）每个任务包含一个新类别。
2) **情景-2（S2）：**T_1包含前15个类别，T_2包含剩余的5个类别。
3) **情景-3（S3）：**T_1包含前10个类别，T_2包含其余10个类别。
4) **场景-4（S4）：**T_1包含最初的19个类别，而T_2包含最后一个类别。

*3) **DMT-II： CBRS 推理测试：***为验证所提技术在推理过程中的鲁棒性，本研究使用了两个完全不同的数据集：Bosch小型交通灯数据集[46]和 KITTI 二维目标检测2012数据集[47]（一个真实世界数据集[48]），用于训练两个独立分支分别检测交通灯状态和交通目标。性能比较从准确率和速度三个方面进行：当各分支单独运行时、组合为AMOD 分支时，以及作为两个独立并行检测器（IPDx2）协同工作时。

*4) **DMT-III： VDS 推理测试：***该测试与DMT-II相同。采用Nvidia Jetson Orin Nano板卡（一种GPU和内存容量有限的边缘设备）。检测器模型保持不变，因其同样兼容该边缘设备[12]。

*5) **DMT-IV：模型复杂度测试：***通过评估所有可能分支组合的计算复杂度与空间复杂度，确定最优分支数量。本研究采用启发式方法选择分支数量。此外，所提出的双分支模型的计算复杂度与两个独立并行检测器的计算复杂度进行了比较。

B. *ABRST*

对于场景中给定的一组类别C'，C，实验的目标是验证以下条件是否成立：

a. 其符合方程（16）中描述的条件。
b. $\hat{}\ Ccloud\ C_{\text{edge}}$，其中$\hat{}\ Ccloud$和$C_{\text{edge}}$分别是云服务器和边缘GPU检测到的类别集。
c. 该产品对不同天气条件具有良好的耐受性。

C. 实验设置

本研究提出以下实验方案。

*1) **DMT设置：***

- **软件配置：**针对检测器模型相关测试，采用YOLOv3代码库[41]并进行修改以分离 CFE 并添加多个CDB。优化过程中采用动量为0.9、权重衰减为5×10^{-4}的随机梯度下降算法。学习率采用余弦调度策略，预热期为2次迭代。每个任务训练50个周期，批量大小为8。
- **硬件配置：**训练在单个工作站（WS-1）上进行，该工作站配备 NVIDIA 2080Ti显卡、2.2GHz英特尔至强处理器及32GB内存。DMT-II测试使用WS-1，DMT-III测试则采用配备16GB内存的NvidiaJetsonOrinNano（Jon-1）平台。

*2) **ABRST 设置：**由于该系统已在*

采用硬件在环（HIL）模式的模拟环境包含四个主要组成部分：环境模拟器（ESS）、 CBRS 服务器、 VDS 及通信中间件（COM）。软硬件配置如下：

- **软件设置：**
  a. **ESS：**Carla（v0.9.15）是一款开源模拟器[49]，用于创建环境及配备摄像头的自我车辆。天气条件可动态切换为晴天、雨天、雾天和夜间四种状态。
  b. **CBRS 服务器：**使用YOLOv3双分支模型作为服务器检测器模型，用于检测：
     i. KITTI 对象类
     ii. 博世交通信号物体分类
  c. **VDS ：**YOLOv3模型采用单检测分支架构，即KITTI 对象类别检测器。
  d. **COM：**机器人操作系统2（ROS2）[50]用于实现所有组件间的通信，其中每个模块作为特定主题的订阅者或发布者节点。每个模块可包含多个节点，这些节点可与不同主题进行交互。
- **硬件配置：**
  a. **ESS：**用于模型训练的WS-1同时作为环境仿真服务器（ESS）使用。
  b. **CBRS ：**该 CBRS 同样运行于WS-1系统。
  c. **VDS ：**Jon-1被用作DMT-II测试中的HIL MPU。
  d. **COM：**COM硬件由三部分组成：
     d.1 **高速以太网交换机（HSES）：**采用 D-Link DMS106XT设备连接ESS、 CBRS 及 VDS 硬件。
     d.2 **LUI：**采用罗技G29游戏方向盘-踏板组合作为本地用户界面。
     d.3 **ROS人机界面（RHUI）：**采用树莓派5B板作为 RHUI 设备，运行ROS2节点“G29发布器”进行数据发布

     LUI数据。该数据也与 HSES 相关联。实验装置如图3所示。

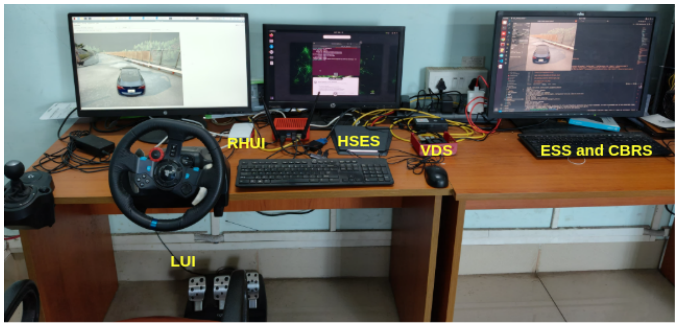

图3：基于云的 AMOD 框架。

D. 结果

结果整理如下：

*1) **DMT结果：**DMT的测试结果如下：*

i. **DMT-I：**S1-S4的对比实验结果（详见V-A1章节）分别列于表II V中。各列显示在IoU阈值为0.5时的类别平均精度（AP），最右侧列则对应平均平均精度（mAP）。结果表明，所提出的系统性能优于先前研究。

ii. **DMT-II与DMT-III：**性能结果如表VI所示。实验结果表明，所提出的 AMOD 方法在实时融入新检测类别时，其速度优于运行两个并行检测器（IPD × 2）的方式。可以推测，随着并行检测器数量的增加，性能差异将进一步扩大。此外，由于 CBRS 和 VDS 采用相同模型且仅通过调整分支数量实现性能差异（即CBRS 比 VDS 具有更多分支），其mAP值保持一致。DMT-II与DMT-III的样本检测结果如图4所示。其中图4a展示了 CBRS（DMT-II）的检测结果——由于配备两个目标检测分支，系统同时实现了交通信号灯与车辆的检测；而图4b则呈现了 VDS（DMT-III）的检测效果，由于硬件资源限制仅使用交通信号灯检测分支，因此仅能识别交通信号灯。

iii. **DMT-IV：**测试结果见表VII。值得注意的是，除单分支情况外，在顶部行中，计算复杂度和空间消耗与对象类在各分支中的分布无关而保持一致。因此，对于任意数量的类别，通过评估给定分支数量下的单一类别分布，即可高效确定其计算复杂度与内存消耗量。从表VII中还可以观察到，尽管可重构性有所提升，但分支数量的增加会导致内存消耗和计算复杂度显著上升。如表II-V所示，在保持整体准确率不变的情况下，计算资源与内存需求会随着分支数量的变化呈现显著差异。因此，选择最佳分支数量至关重要。如第III节所述，该优化效果得以实现

表II：DMT-I S1 -PER-CLASSAP与总体MAP值（基于PASCALVOC指标）——当向基于第一 15 类别训练的检测器中逐个添加5个新类别时

班级拆分	方法	气候	循环	鸟	船	瓶	巴士	汽车	猎犬	桌子	牛	狗	马	自行车	人	植物	宠物	沙发	列车	电视	mAP
(1-15)+16	所有15	87.0	90.0	88.8	87.0	66.2	74.0	83.2	89.3	87.8	65.2	84.6	90.0	86.8	66.0	76.8	79.4	89.7	68.1	89.1	90.9
	级	级		89.2	87.2	67.5	73.3	90.5	66.8	89.2	90.7	86.6	86.3	86.8	86.5	51.6	85.2	77.0	85.7	83.3	81.1
	[43]	70.5		78.3	69.6	60.4	52.4	70.2	56.7	77	80.3	78.1	70	79.2	47.1	–	–	–	–	–	83.0
	[9]	78.8		79	65.9	51.8	57.3	77	60.4	76	81.8	76.9	80.6	76.1	84.2	26.3	–	–	–	–	67.0
	建议值	90.0		89.2	87.2	67.5	73.3	90.5	66.8	89.2	90.7	86.6	86.3	80.3	47.3	33.3	–	–	–	–	69.2
														84.6	90.0	54.9	–	–	–	–	**81.2**
														86.8	66.0						
(1-15)+16+17	[43]	70.3	78.9		67.7	59.2	47	76.3	79.3	77.7	48	79.6	84.9	79	47.3	58.8	60.2	67.4	71.6	78.6	70.2
	[9]	80.1	79.9		66.2	53.4	58.4	72.9	60.7	73.7	81.2	78.3	80.4	84.6	90.0	27.9	46.8	–	–	–	63.9
	建议值	90.0	89.2		87.2	67.5	73.3	90.5	66.8	89.2	90.7	86.6	86.3	86.8	66.0	35.5	56.3	–	–	–	68.7
																54.9	86.5	–	–	–	**81.5**
(1-15)+16+ · · ·	+18 [43]	69.8		78.2	67.0	50.4	46.9	76.5	78.6	78	46.4	78.4	85.0	77.5	46.3	58.6	58.6	67.5	71.8	78.5	69.9
	[9]	80.1	提议值	79.4	65.0	53.2	58	72.9	59.2	74.1	81.4	75.7	79.9	84.6	90.0	26.1	56.2	45.3	–	–	62.5
		90.0		89.2	87.2	67.5	73.3	90.5	66.8	89.2	90.7	86.6	86.3	86.8	66.0	35.4	55.8	50.0	–	–	67.1
																54.9	86.5	79.0	–	–	**81.4**
(1-15)+16+ · · ·	+19 [43]	70.4	78.8	67.3	49.8	46.4	75.6	78.4	78	46	74.9	84.1	79.1	46.4	84.6	59.5	59.2	67.2	71.8	71.3	69.8
	[9]	77.7	78.5	67.1	51.9	56.9	71.8	59.4	72.5	81.6	75.6	79.5	90.0	86.8	66.0	25.9	56.1	48.2	65.0	–	62.4
	提议值	90.0	89.2	87.2	67.5	73.3	90.5	66.8	89.2	90.7	86.6	86.3				33.5	58.2	49.4	65.5	–	66.5
																54.9	86.5	79.0	85.5	–	**81.6**
(1-15)+16+ · · ·	+20 [43]	70.0	78.1	61.0	50.9	46.3	76.0	78.8	77.2	46.1	73.7	83.6	76.7	45.2	84.6	66.6	58.9	67.7	71.6	71.4	69.6
	[9]	77.5	77.1	66.58	53.6	55.0	74	57.7	72.4	81.3	77	79.1	90.0	86.8	66.0	25.6	57.10	46.50	70.70	58.20	62.4
	提议值	90.0	89.2	87.2	67.5	73.3	90.5	66.8	89.2	90.7	86.6	86.3				34.9	58.1	49.6	67.5	53.7	65.7
																54.9	86.5	79.0	85.5	83.2	**81.6**

表III：DMT-I S2 -PER-CLASSAP与总体MAP值（基于PASCALVOC指标）——当检测器训练基于前 15 类别时新增5个类别的情况

班级划分	方法	空气	循环	鸟	船	瓶子	公交车	汽车	猫	椅	牛	桌	狗	马	自行车	人	植物	宠物	沙发	列车	电视	mAP
15+5	所有类别	87.0	88.8	87.0	66.2	74.0	83.2	89.3	87.8	65.2	89.7	68.1	89.1	90.9	86.8	86.5	51.6	85.2	77.0	85.7	83.3	81.1
	15 课	90.0	89.2	87.2	67.5	73.3	84.6	90.0	86.8	66.0	90.5	66.8	89.2	90.7	86.6	86.3	–	–	–	–	–	83.0
	[43]	70.5	79.2	68.8	59.1	53.2	75.4	79.4	78.8	46.6	59.4	59	75.8	71.8	78.6	69.6	33.7	61.5	63.1	71.7	62.6	65.9
	[9]	78.4	79.7	66.9	54.8	56.2	77.7	84.6	79.1	47.7	75	61.8	74.7	81.6	77.5	80.2	37.8	58	54.6	73	56.1	67.8
	建议	90.0	89.2	87.2	67.5	73.3	84.6	90.0	86.8	66.0	90.5	66.8	89.2	90.7	86.6	86.3	51.2	85.7	75.8	82.4	82.4	**81.1**

表IV：当向基于第一 10 类别的检测器训练模型中添加新类别时，DMT-I S3 PER-CLASS AP与PASCAL VOC总体MAP值

班级划分	方法	空气	循环	鸟	船	瓶子	公交车	汽车	猫	椅	牛	桌	狗	马	自行车	人	植物	宠物	沙发	列车	电视	mAP
10+10	所有类别	87.0	88.8	87.0	66.2	74.0	83.2	89.3	87.8	65.2	89.7	68.1	89.1	90.9	86.8	86.5	51.6	85.2	77.0	85.7	83.3	81.1
	前10	86.8	89.1	86.4	70.1	71.4	83.9	89.1	86.8	65.6	85.2	–	–	–	–	–	–	–	–	–	–	81.4
	[43]	69.9	70.4	69.4	54.3	48.0	68.7	78.9	68.4	45.5	58.1	59.7	72.7	73.5	73.2	66.3	29.5	63.4	61.6	69.3	62.2	63.1
	[9]	76	74.6	67.5	55.9	57.6	75.1	85.4	77	43.7	70.8	60.1	66.4	76	72.6	74.6	39.7	64	60.2	68.5	60.5	66.3
	建议	86.8	89.1	86.4	70.1	71.4	83.9	89.1	86.8	65.6	85.2	66.9	89.0	90.7	86.0	86.4	52.7	83.6	76.4	84.9	83.5	**80.7**

表V：DMT-I S4 -按类别AP值及总体MAP值（基于PASCAL VOC指标）——当最后一次类别被添加至基于第一 19 类

别训练的检测器时

班级划分方法		空气	循环	鸟	船	瓶子	公交车	汽车	猫	椅	牛	桌	狗	马	自行车	人	植物	宠物	沙发	列车	电视	mAP
	所有87.0级和88.8级		87.0	66.2	74.0	83.2	89.3	87.8	65.2	89.7	68.1	89.1	90.9	86.8	86.5	51.6	85.2	77.0	85.7	83.3	81.1
	第一19	88.8	88.8	86.9	68.6	71.9	83.7	89.7	87.5	65.4	90.3	69.6	89.7	89.8	86.7	86.8	53.3	85.3	76.2	86.7	–	81.4
19+1	[43]	69.4	79.3	69.5	57.4	45.4	78.4	79.1	80.5	45.7	76.3	64.8	77.2	80.8	77.5	70.1	42.3	67.5	64.4	76.7	62.7	68.3
	[9]	78.2	77.5	69.4	55	56	78.4	84.2	79.2	46.6	79	63.2	78.5	82.7	79.1	79.9	44.1	73.2	66.3	76.4	57.6	70.2
	建议	88.8	88.8	86.9	68.6	71.9	83.7	89.7	87.5	65.4	90.3	69.6	89.7	89.8	86.7	86.8	53.3	85.3	76.2	86.7	83.2	**81.4**

表VI：DMT-II与DMT-III—— CBRS 与 VDS 中探测器性能对比

探测器	推理时间（毫秒）		速度提升百分比		mAP（%）
	CBRS*	VDS**	CBRS*	VDS**	
AMOD	28.57	142.86	4.2	9.0	60.62
IPDx2平均值	29.85	156.99	–	–	60.74
* CBRS : Intel ® Xeon @ 2.20GHz，32GB RAM，Nvidia GTX 2080Ti					
** VDS ：英伟达Jetson Orin Nano处理器，配备8GB内存					

首先计算可重构性分数S_R（·）、计算复杂度分数S_C（·）、总体分数$S(\cdot)$，最后应用内存约束M_{Max}。从表VII可以看出，对于8个对象类，当分支数量为2时可获得最佳总体分数0.552。此外，若将硬件内存约束M_{Max}设置为250MB，最大分支数量仍需为2。此处，权重w_1和w_2在（14）中保持为0.5。然而，根据硬件可用性以及对可重构性或资源效率的要求，这些参数可以进行调整。相关详细计算结果已发布在关联的GitHub仓库[38]中。表VI-II列出了IPDx2与 AMOD 在计算复杂度、内存复杂度及其百分比差异方面的对比数据。

*2) **ABRST 结果：*** ABRST 测试结果如图所示。

5. 存在两组作为真实标注的对象类别，即：i. 交通对象：汽车和行人。

ii. 交通信号灯具有红、黄、绿三种状态。对于每组对象类别， CBRS 中均设有检测分支，因此可同时检测所示两类类别中的对象。

表VII：8个目标类别中DMT-IV分支组合

分支	班级	每秒十亿次浮点运算数	兆字节	SR（·）	SC（·）	$S(\cdot)$
1	8	16.853	117.258	0.000	1.000	0.500
2	1,7	33.643	231.790	0.333	0.771	**0.552**
	2,6	33.643	231.790			
	3,5	33.643	231.790			
	4,4	33.643	231.790			
3	1,1,6	50.433	346.323	0.528	0.571	0.550
	1,2,5	50.433	346.323			
	1,3,4	50.433	346.323			
	2,2,4	50.433	346.323			
	2,3,3	50.433	346.323			
4	1,1,1,5	67.222	460.855	0.667	0.400	0.534
	1,1,2,4	67.222	460.855			
	1,1,3,3	67.222	460.855			
	1,2,2,3	67.222	460.855			
	2,2,2,2	67.222	460.855			
5	1,1,1,1,4	84.012	575.388			
	1,1,1,2,3	84.012	575.388	0.774	0.257	0.516
	1,1,2,2,2	84.012	575.388			
6	1,1,1,1,1,3	100.802	689.920	0.862	0.143	0.503
	1,1,1,1,2,2	100.802	689.920			
7	1,1,1,1,1,1,2	117.591	804.453	0.936	0.057	0.497
8	1,1,1,1,1,1,1,1	134.381	918.985	1.000	0.000	0.500

表格首列显示分支数量，次列列出所有可能的分支-类组合，其总数等于类别总数。例如，当存在两个分支和八个对象类时，有效组合包括(1,7)、(2,6)、(3,5)和(4,4)。同理，若分支数量为八，则唯一可能的组合为(1,1,1,1,1,1,1,1)。

表VIII：DMT-IV - IPD 与 AMOD 的复杂性分析

复杂性	IPDx2	AMOD	改善
每秒十亿次浮点运算数	142.24	87.92	38.2%
内存复杂度（MB）	1755	993.5	43.4%

(a) (b)

图4：a) 使用[46]和[47]同时检测交通灯状态（蓝色边界框）与交通物体（棕色边界框）；b) 使用[46]仅检测交通灯状态（红色边界框）

.

如图5a所示。然而，由于 VDS 仅使用单个分支来处理交通信号状态，因此仅能检测交通信号灯；未实现交通物体检测，如图5b所示。然而，无论是 CBRS 还是 VDS，探测器均能在晴天、雾天/雨天及夜间条件下检测目标，从而验证其在不同天气条件下的稳健性。

(a) 通播接收台

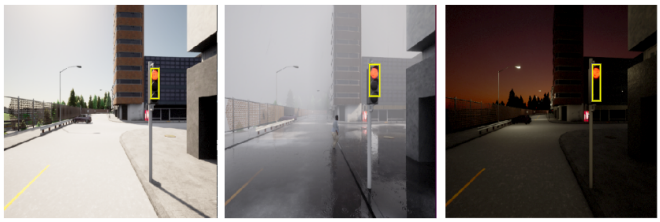

(b) VDS

图5： ABRST 测试结果：(a) CBRS 与(b) VDS 检测结果（黄色边界框）在晴天、雾天/雨天及夜间环境下的表现。

VI. 结论

可以得出结论：虽然现有的知识蒸馏和元学习技术有助于缓解灾难性遗忘问题，但往往会导致平均精度下降。尽管采用多个独立网络可以解决该问题，但会将存储空间和计算复杂度翻倍。相比之下，本文提出的方法同时解决了灾难性遗忘和内存复杂度两大挑战，这使得该方法成为在移动中于车辆边缘GPU部署时，针对目标对象类别重构检测器模型的实用解决方案。

尽管所提出的方法是在边缘GPU上实现的，但大多数车辆配备的计算资源较为有限。因此，未来需要进一步探索模型与检测器-跟踪器组合的优化方案。在车联网通信中，当基于云端的分店推荐系统不可用时，具备较强处理能力的邻近车辆可充当分店推荐系统。

参考文献

[1] S. Yang、W. Wang、C. Liu和W. Deng，《基于深度学习的自动驾驶车辆端到端控制器中的场景理解》，*IEEE系统、人与控制论汇刊*，第49卷第1期，第53–63页，2019年。

[2] Y. Zhao、L. Wang、X. Yun、C. Chai、Z. Liu、W. Fan、X. Luo、Y. Liu与X. Qu，《基于语义分割的自动驾驶车辆场景理解与情境感知增强》，*IEEE系统、人与控制论汇刊*，第54卷第11期，第6537–6549页，2024年。

[3] L. Chen、S. Teng、B. Li、X. Na、Y. Li、Z. Li、J. Wang、D. Cao、N. Zheng和F.-Y. Wang，《自动驾驶与智能车辆发展里程碑——第二部分：感知与规划》，*IEEE系统、人与控制论汇刊*，第53卷第10期，第6401–6415页，2023年。

[4] L. Dal ‘Col、M. Oliveira 和 V. Santos，《自动驾驶中的联合感知与预测：综述》，IEEE智能交通系统汇刊，第26卷，第12期，第21427–21452页，2025年。

[5] W. Zhou、T. Gong、J. Lei和L. Yu，“DBCNet：用于智能车辆RGB-T城市场景理解的动态双边交叉融合网络”，*IEEE系统、人与控制论汇刊*，第53卷第12期，第7631–7641页，2023年。

[6] A. Krizhevsky、I. Sutskever 和 G. E. Hinton，《基于深度卷积神经网络的ImageNet分类》，*ACM通讯*，第60卷，第84–90页，2017年5月。

[7] R. Girshick，J. Donahue，T. Darrell与J.Malik合著的《Accurate Object检测与Semantic Segmentation的Rich Feature层次结构》，收录于*2014年IEEE Computer Vision 与 Pattern Recognition 会议*，第580–587页，2014年。

[8] R. Girshick，“Fast R-CNN，” 收录于*2015年IEEE国际计算机视觉会议(ICCV)*，第1440–1448页，2015年.

[9] K. J. Joseph、J. Rajasegaran、S. Khan、F. S. Khan 和 V. N. Balasubramanian，《基于元学习的增量目标检测》，*IEEE模式分析与机器智能汇刊*，第44卷第12期，第9209–9216页，2022年。

[10] 程先生、王浩和龙宇，“基于元学习的增量少样本目标检测”，*IEEE Transactions《Video Technology 电路与系统》*，第32卷第4期，第2158–2169页，2022年。

[11] A. Setyanto、T. Bayu Sasongko、M. A. Fikri、D. Ariatmanto、I. M. A. Agastya、R. D. Rachmanto、A. Ardana 和 I. K. Kim，《资源受限边缘计算中目标检测的知识蒸馏》，*IEEE Access*，第13卷，第18200–18214页，2025年。

[12] S. Liang、H. Wu、L. Zhen、Q. Hua、S. Garg、G. Kaddoum、M. M. Hassan 和 K. Yu，《边缘YOLO：基于自动驾驶车辆边缘-云协作的实时智能目标检测系统》，*IEEE智能交通系统汇刊*，第23卷第12期，第25345–25360页，2022年。

[13] Y. Wang、Z. Liu、H. Lin、J. Jiang、S. Xu与J. Wang合著的《Pre-GSU：基于预训练图注意力网络的自动驾驶通用交通场景理解模型》，发表于*IEEE系统、人与控制论汇刊*第55卷第12期，第9604–9616页，2025年。

[14] 高H、朱J、张T、谢G、坎Z、郝Z与刘K合著的《基于随机模型与高斯分布的典型交通场景下智能车辆情境评估》发表于*IEEE Transactions。《系统、人与控制论：系统》*，第52卷第3期，第1426–1436页，2022年。

[15] M. A. Iqbal、Y. C. Yoon、M. U. S. Khan与S. K. Kim合著的《基于类别特征空间学习的开放世界目标检测改进方法》，*IEEE Access*期刊第11卷，第131221–131236页，2023年。

[16] 刘W、安格洛夫D、埃尔汉D、塞格迪C、里德S、傅C.-Y及伯格A. C.合著的《SSD：单次拍摄多目标检测器》，收录于*计算机视觉——ECCV 2016*（B.莱贝、J.马塔斯、N.塞贝与M.韦林编），瑞士夏姆出版，第21–37页，施普林格国际出版集团，2016年。

[17] J. Redmon，S. Divvala，R. Girshick与A.Farhadi合著的《You Only Look Once：统一的实时Time Object检测》，收录于*2016年IEEE计算机视觉与Pattern Recognition会议（CVPR）*，第779–788页，2016年。

[18] J. Redmon与A. Farhadi，《YOLOv3：渐进式改进》，*ArXiv*，卷号abs/1804.02767,2018年。

[19] S. Ren、K. He、R. Girshick和J. Sun，《更快的R-CNN：基于区域提议网络的实时目标检测》，*IEEE模式分析与机器智能汇刊*，第39卷第6期，第1137–1149页，2017年。

[20] L. 张、X. 杨、K. 张、Y. 李、F. 李、J. 李及D.李，《基于异常检测的类增量学习》，*IEEE Access*，第11卷，第69423–69438页，2023年。

[21] G. Hinton、O. Vinyals 和 J. Dean，《神经网络中的知识提炼》，*arXiv 预印本 arXiv:1503.02531*，2015年。

[22] M. Andrychowicz、M. Denil、S. G. Colmenarejo、M. W. Hoffman、D. Pfau、T. Schaul、B. Shillingford与N. de Freitas合著的《通过梯度下降法实现梯度下降学习》，收录于*第30届国际神经信息处理系统会议论文集*（NIPS‘16，美国纽约州红钩市），第3988–3996页，Curran Associates Inc.，2016年。

[23] S. Kullback与R. A. Leibler合著的《论信息与充分性》，发表于*《数理统计年鉴》*第22卷第1期，第79–86页，1951年。

[24] Y. Hao，Y. Fu，Y. -G.Jiang与Q.Tian合著的《基于Knowledge Distillation的类别Incremental Object检测An End-to-End架构》，收录于*2019年IEEE多媒体与展览International Conference（ICME）*，第1-6页，2019年。

[25] L. Chen、C. Yu 和 L.陈，《用于Incremental Object检测的New Knowledge蒸馏法》，*2019年International Joint Neural Networks会议（IJCNN）*，第1–7页，2019年。

[26] S. Hou，X. Pan，C. C. Loy，Z. 王和D.Lin，《通过再平衡逐步学习Unified Classifier》，收录于*2019年IEEE/ CVF Computer Vision 与 Pattern Recognition 会议(CVPR)*，第831–839页，2019年。

[27] Z. Yang、B. Wang、Y. Li、S. Ding 和 P. Jiang，《无人水面舰艇的增量目标检测》，*2022年中国自动化大会（CAC）*，第6161–6166页，2022年。

[28] W· Li，Q. · Wu，L. ·徐与C·尚合著《Singlestage Detectors 与 Mining Memory 神经元的 Incremental Learning》，收录于*2018年IEEE第四届计算机与通信International Conference（ICCC）*，第1981–1985页，2018年。

[29] T. Gkaragkanis与A. Likas合著的《MultiYOLO：无需完整再训练即可学习新YOLO类别》，收录于*《高级机器智能与信号处理》*（D. Gupta、K. Sambyo、M. Prasad及S. Agarwal主编），新加坡：Springer Nature Singapore出版社，2022年，第259–268页。

[30] A. 坦布韦卡尔、K. 阿格拉瓦尔、A. 马吉及A.Subramanian，“通过Detector Fusion 实现少 Shot Batch Incremental Road Object Detection”，*2021 IEEE/ CVF Computer Vision 工作坊 International Conference（ICCVW）*，第3063–3070页，2021年。

[31] J. Zhang、J. Zhang、S. Ghosh、D. Li、S. Tasci、L. Heck、H. Zhang和C.-C. J. Kuo，《通过深度模型整合实现类别增量学习》，收录于*IEEE/ CVF 计算机视觉应用冬季会议论文集（WACV）*，第1131–1140页，2020年3月。

[32] Y. Wu、Y. Chen、L. Wang、Y. Ye、Z. Liu、Y. Guo和Y. Fu，《大规模增量学习》，收录于*IEEE/ CVF 计算机视觉与模式识别会议论文集*，第374–382页，2019年。

[33] B. Zhao，X. Xiao，G. Gan，B. 张和夏思婷（S.-T.Xia），“Class Incremental 学习中的 Maintaining Discrimination 与公平性”，收录于*2020年IEEE/ CVF 计算机视觉与 Pattern Recognition 会议（CVPR）*，第13205–13214页，2020年。

[34] F. M. 卡斯特罗，M. J. 马尔ın -吉姆énez、N. Guil、C. Schmid与K. Alahari合著的《端到端增量学习》，收录于*欧洲计算机视觉会议（ECCV）论文集*（瑞士夏姆），第xx页。241–257，Springer国际出版集团，2018年。

[35] T.-Y. Wu、G. Swaminathan、Z. Li、A. Ravichandran、N. Vasconcelos、R. Bhotika和S. Soatto，《基于强预训练模型的类别增量学习》，收录于*IEEE/ CVF 计算机视觉与模式识别会议（CVPR）论文集*，2022年。

[36] J. Peng、M. Sun、Z.-X. Zhang、T. Tan和J. Yan，“POD：基于尺度敏感网络的实用目标检测”，*2019 IEEE/ CVF 国际计算机视觉会议(ICCV)*，第9606–9615页，2019年。

[37] S.-A. Rebuffi，A. Kolesnikov，G. Sperl与C.H.Lampert合著的《iCaRL：Incremental Classifier 与 Representation Learning》，收录于*2017年IEEE计算机视觉与Pattern Recognition会议（CVPR）*，第5533–5542页，2017年。

[38] A. Majumder，《分支分析》。https://github.com/abhrasky/BranchAnalysis。访问日期：2025年12月8日。

[39] M. Everingham、L. Van Gool、C. K. I. Williams、J. Winn 和 A. Zisserman，《Pascal视觉对象类（VOC）挑战赛》，*国际计算机视觉杂志*，第88卷第2期，第303–338页，2010年。

[40] H. Rezatofighi、N. Tsoi、J. Gwak、A. Sadeghian、I. Reid 及 S. Savarese，“Generalized Intersection Over Union : Bounding Box 回归中的度量与损失，”收录于*2019 IEEE/ CVF Computer Vision 与 Pattern Recognition 会议(CVPR)*，第658–666页，2019年。

[41] Peterisfar，“YOLOv3实现。”https://github.com/Peterisfar/YOLOV3。访问日期：2025年12月8日。

[42] T.-Y. Lin、P. Goyal、R. Girshick、K. He 和 P. Dollár，《密集目标检测中的焦点损失》，*2017年IEEE国际计算机视觉会议(ICCV)*，第2999–3007页，2017年。

[43] K. Shmelkov、C. Schmid与K. Alahari合著的《无灾难性遗忘机制下的目标检测器增量学习》，收录于*IEEE国际计算机视觉会议（ICCV）论文集*第3400–3409页，2017年。

[44] D. Zhou、J. Fang、X. Song、C. Guan、J. Yin、Y. Dai 和 R. Yang，“二维/三维目标检测中的IoU损失函数”，*2019年国际三维视觉会议（3DV）*，第85–94页，2019年。

[45] J. Deng、W. Dong、R. Socher、L.-J. Li、K. Li 和 L. Fei-Fei，《ImageNet：大规模分层图像数据库》，收录于*IEEE计算机视觉与模式识别会议（CVPR）论文集*，第248–255, 2009.

[46] K. Behrendt，L. ·诺瓦克与R.博特罗斯合著的《Traffic Lights 的 Deep Learning 方法：检测、跟踪与分类》，收录于*2017年IEEE机*

器人与自动化 International Conference（ICRA），第1370–1377页，IEEE出版社，2017年。

[47] A. Geiger，P. ·伦茨与R.乌尔塔松合著《 Are We 准备好 Autonomous Driving 了吗？ The Kitti Vision Benchmark 套件》，收录于*2012年IEEE Computer Vision 与 Pattern Recognition 会议*，第3354–3361页，2012年。

[48] 刘先生、E. Yurtsever、J. Fossaert、X. Zhou、W. Zimmer、Y. Cui、B. L. Zagar和A. C. Knoll，《自动驾驶数据集综述：统计分析、标注质量及未来展望》，*IEEE 智能车辆汇刊*，第9卷第11期，第7138–7164页，2024年。

[49] A. Dosovitskiy、G. Ros、F. Codevilla、A. Lopez 和 V. Koltun，"carla：一个开放的城市驾驶模拟器"，收录于*第一届机器人学习年会论文集*，*机器学习研究论文集* 第78卷，第1-16页， PMLR，2017年11月13-15日。

[50] T. Betz、M. Schmeller、H. Teper与J. Betz合著的《我的软件运行速度有多快？基于ROS 2自动驾驶软件的延迟评估》，收录于*2023年IEEE智能车辆研讨会（IV）*第1–6页，2023年。