

RESEARCH ARTICLE

基于视频监控摄像头的实时火灾检测：我们目前处于什么阶段？

文森佐·CARLETTI¹, (IEEE会员), 安东尼奥·格雷科¹, (IEEE会员)

ALESSIA SAGGESE¹ (IEEE会员), 以及布鲁诺·VENTO²

¹萨莱诺大学信息与电气工程及应用数学系, 意大利菲斯恰诺市, 邮编84084

²那不勒斯费德里科二世大学电气工程与信息技术系 (DIETI), 意大利那不勒斯80138。通讯作者: 安东尼奥·格雷科 (agreco@unisa.it)

摘要视频监控中的自动火灾检测是保障工业场所、公共基础设施及自然环境安全的关键能力。尽管深度学习领域的最新进展显著提升了早期火灾检测能力, 但现有方法的性能仍高度依赖于场景条件 (如观测范围、背景活动情况以及类似火灾的干扰因素)。本文基于 ONFIRE 和 FIRE-TASTIC 基准集——目前视频火灾监测领域最全面的数据集——对实时火灾检测技术进行了全面评估。通过系统比较在检测器质量、时序建模能力和语义推理能力方面存在差异的方法, 我们明确了当前设计范式的优缺点, 并分析了其在不同观测距离及背景活动条件下表现的特点。研究结果揭示了明显的性能趋势, 凸显了精准的检测器训练、场景感知适配、时序分析以及轻量级视觉-语言融合技术的关键作用。基于这些见解, 我们提出了若干具有前景的研究方向, 包括开发更具代表性的数据集、改进语义确认模块, 以及制定能够在动态实际部署环境中保持可靠性的稳健持续学习策略。

索引词: 火灾检测、视频监控、实时计算机视觉、深度学习、时序分析、视觉-语言模型、场景感知检测。

1. 引言

火灾仍然是对人类生命、建筑环境及自然生态系统影响最严重的危害之一[1]。在工业区和农村地区, 这一风险尤为突出, 因为可燃材料、电气基础设施和机械设备往往是引火源。此外, 气候变化的影响正在加剧这一威胁: 全球气温上升[2]与持续干旱期及极端天气条件日益相关, 这进一步提高了全球火灾的发生频率和严重程度[3]。[4]在此背景下, 能够在火灾发生初期及时识别火情对于减轻损失和支持快速应急处置至关重要。

近年来, 视频监控系统已作为环境监测与关键安全系统的组成部分得到广泛应用。

负责协调本稿件审阅并批准其发表的副主编为李川。

基础设施监控策略。这一趋势加速了对基于计算机视觉的可靠自动火灾检测方法的需求。早期研究主要依赖于从摄像头视频流中提取的低级颜色特征或简单运动描述符。尽管这些方法计算量较小, 但无法应对现实视频数据中存在的显著变化因素, 例如光照变化、与摄像头的距离差异、大气干扰以及摄像机噪声等。

基于机器学习和深度神经网络的更先进方法已显著提升了检测灵敏度。然而, 这些方法仍面临两个持续存在的挑战。首先, 火焰的视觉外观会因规模、观察角度及场景动态的不同而存在显著差异, 这些特征往往与训练数据中的表现有所不同; 当火焰或烟雾尺寸较小或部分被遮挡时, 便可能导致漏检。其次, 具有类似火焰颜色或运动模式的非火灾物体也可能被误判为火焰。

会触发误报，尤其在车辆灯光、移动机械或云层存在时。

近期对该领域的分析揭示了两个主要不足之处。首先，大多数火灾检测系统缺乏对不同场景的充分认知[5,]。监控画面中既存在火源靠近摄像头且清晰可见的情况（短距离），也存在火焰仅占据少数像素或因遮挡或烟雾扩散而间歇出现的情形（长距离）。此外，背景活动水平——从安静的静态环境到包含动物、车辆、机械或植被的高度动态场景——都会直接影响类火灾干扰信号的类型和出现频率。[5]提出的分类体系将这些因素归纳为四种典型场景（低活动度短距离、低活动度长距离、高活动度短距离、高活动度长距离），凸显了距离与活动强度共同决定了火灾检测的难度。未能根据这些情境因素调整推理策略的系统往往表现出不一致的性能表现。

在简单场景中表现出高灵敏度，但在复杂或远距离情况下易出现误报或漏检。

第二个差距已通过 ONFIRE 竞赛结果得到证实[6,]。[7]的核心问题在于：即使是最先进的检测器和更复杂的检测方法，尽管具有极高的灵敏度，仍可能产生过多的误报。这一局限性通常源于训练数据集主要包含简单场景或低活动度场景，这限制了这些方法在应对更真实场景（如存在多种移动或发光物体模拟火灾特征的情况）时的泛化能力。这些缺陷凸显了当前研究面临的一个更广泛挑战：如何在现实监控场景的整个范围内实现稳健性能——从简单的短距离目标捕捉到充满类似火灾干扰物的高活动度复杂场景均需应对。

基于这些观察结果，本研究对实时视频火灾检测的现状进行了系统性分析。具体而言，我们在 ONFIRE [8]和FIRE-TASTIC [9]测试集所呈现的复杂多变条件下评估现有方法——这两个数据集目前是监控场景火灾检测领域最全面的基准测试集。通过分析不同检测策略在不同场景复杂度及场景类别下的表现，本研究不仅明确了现有方法的局限性，还提出了弥合实验室高精度与实际应用场景中稳健性能之间差距的新研究方向。特别值得注意的是，我们的研究强调了场景感知模型、更丰富的数据集、更高效的时间与语义推理能力以及先进的自适应机制对提升未来火灾检测系统鲁棒性的重要性。

二、相关研究成果

自21世纪初以来，由于其优势，传统光学相机在火灾检测中的应用已得到广泛研究。

低成本且易于部署。早期基于视觉的系统主要依赖于在定制颜色空间中采用启发式颜色阈值处理方法[10,]。[11]，有时会辅以烟雾特异性分割模块来捕捉早期阶段特征[12]。尽管这些手工设计的方法计算量较小，但对光照变化极为敏感，并容易混淆类火灾运动，导致在复杂环境中鲁棒性较差。

为克服这些局限性，时间推理技术通过闪烁分析、运动稳定性检测或形状演化描述符等方式被逐步整合[13,]。[14],[15],[16],[17],[18],[19]。尽管这些基于规则的多阶段系统提升了可靠性，但其人工设计的特性限制了在不同场景下的可扩展性。

机器学习技术的引入使得纹理和外观建模更加丰富，例如将局部二值模式[20]与支持向量机（SVM）或集成方法[21,]相结合。[22],[23]。这些方法虽优于纯手工构建的流程，但仍受限于人工设计描述符的表达能力局限。

随着深度学习的出现，火灾检测逐渐转向数据驱动的代表方法。其中一个研究方向专注于单图像分析：包括图像级分类[24,]。[25], [26], [27], [28], [29], [30], [31],[32],[33],[34] 或利用高效的CNN进行直接边界框定位。FireNet[32,]、KutnalNet[26]及MSDNet[33 d]等轻量级分类器表明，紧凑架构可在嵌入式设备上实现快速推理，但当火灾仅占据小区域或场景中存在大量类火灾干扰物时其性能会受到影响。与此同时，单帧目标检测器因其能精确定位火焰或烟雾而广受欢迎。基于YOLO的检测器在大型标注数据集（如[7]或]中的 ONFIRE 以及多样化的Focus数据集[35,]）上经过微调后，即使面对小型远距离目标也能表现出优异性能，这证实了高质量异构训练数据的核心作用。

鉴于单帧推理的局限性，时序分析已重新成为现代处理流程中的关键组成部分。近期系统将空间检测器或分类器与时序验证方案相结合，涵盖从简单的持续性规则[36]到更复杂的置信度聚合策略[6]。深度序列模型如今也发挥着重要作用：三维卷积神经网络、双流架构、循环网络以及基于Transformer的编码器均能联合建模图像外观与运动特征[37,]。[38],[39],[40],[41],[42],[43],[44] 这些混合时空分析方法可通过验证火灾的持续性、连贯性及特征动态特性来降低误报率，但需使用规模更大、数据类型更丰富的视频数据集以避免过拟合。

最近，一类新的方法引入了视觉-语言模型（VLMs）以提升语义区分能力[45]。由于VLMs经过数百万图像-文本对的预训练，它们在识别细微视觉特征方面表现卓越。




图1.近期实时火灾检测方法的分类体系，展示了本文讨论的三大主要方法类别。单图像分析方法仅依赖帧级特征，通常采用图像分类器或简单的定位模型，且不涉及时间推理。时空分析方法通过整合随时间追踪火源候选区域的机制来扩展这一框架，从而增强对瞬态伪影的抗干扰能力。最后，基于视觉语言模型的方法将时空分析与语义验证相结合，不仅能提升情境理解水平，还能更精准地区分真实火灾事件与视觉特征相似的干扰信号。

识别火灾概念并区分真实火源与视觉外观相似的物体。诸如FIRE- TASTIC [9]和Focus[35]等系统首先依赖于YOLO的检测器来识别帧级火灾候选对象，并应用时间过滤；仅当存在持续存在的火灾区域需要语义确认时，才会调用BLIP-2等模型进行验证。这种选择性验证策略在保持高灵敏度的同时显著降低了假阳性率，尤其适用于视觉检测难度大或高活性环境。

综上所述，火灾检测技术的发展历程体现了从手工构建的颜色模型到深度时空架构，再到近期融合视觉-语言推理的多模态处理流程的演进过程。

三、火灾探测方法

在接下来的章节中，我们将概述近期发表于基准数据集（我们将在IV-A节中分析）且具备实时运行能力的火灾检测方法。这些方法被划分为图1所示的三大主要类别：第一类采用单图像处理方式，包括基于图像级别的分类或直接对火焰与烟雾进行空间定位；第二类方法则整合空间与时间信息，通过利用运动模式及连续帧间的特征持续性来提升检测可靠性。第三类方法涵盖基于视觉-语言模型的支持方案，这些方案利用大规模图像-文本预训练来语义验证视觉检测结果，并更准确地区分火灾与类火灾物体。表1按所提出的分类体系对相关方法进行了汇总。

A. 单图像分析

本节阐述了专注于单图像分析的方法，这些方法或基于图像级分类，或直接检测单帧图像中的火焰或烟雾区域。此类方法无需时间线索即可运行，因此计算效率高，但本质上对火灾相关的视觉模糊性极为敏感。

基于图像分类的火灾检测方法将每帧图像视为独立图像，在不利用时间线索的情况下为图像标注火灾/非火灾标签。名为FireNet[32 r]的方法采用轻量级CNN分类器（FireNet），能够仅通过单张图像区分火灾与非火灾内容。为确保模型的鲁棒性，研究人员通过将现有数据集样本与新采集并增强后的包含真实火灾图像及类火干扰图像的数据相结合，构建了训练集，使模型能够学习更具普适性的视觉特征。最终得到的网络仅采用三个卷积层并结合丢弃 regularization 进行优化，实现了端到端训练，并能在低成本嵌入式硬件上实时运行。KutralNet[26]i是一种专为火灾检测设计的紧凑型深度学习架构，可显著降低计算成本——其浮点运算量比FireNet减少约92%，可作为评估逆残差块、深度卷积和八度卷积等高效卷积策略的轻量级基准模型。该网络使用包含多样化火灾与非火灾样本的FireNet和FiSmo两个图像数据集进行训练和测试，确保在实际场景中具备稳健性能。Int. Systems Lab[33]提出的方法同样基于单帧分类技术。该研究提出了一种多尺度密集网络（MSDNet）。

表1.根据所提出的分类体系对所考虑火灾检测方法的总结。对于每种方法，该表列出了：(i) 用于单图像分析的技术；(ii) 空间与时间分析的存在情况及性质；以及(iii) 是否采用视觉-语言模型进行语义验证。

Method	Single-image analysis	Spatial and temporal analysis	Support by vision-language models
FireNet [32]	Image classification	-	-
KutralNet [26]	Image classification	-	-
Int. Systems Lab [33]	Image classification	-	-
ShuffleNetV2 [34]	Image classification	-	-
Tendeiro [7]	Fire localization	-	-
Yolov5s [35]	Fire localization	-	-
Yolov8s [35]	Fire localization	-	-
Yolov11s [35]	Fire localization	-	-
Yolov12s [35]	Fire localization	-	-
KIOS-EVAI [6]	Image classification	Fire persistence	-
FIRESTART [42]	Image classification	Fire persistence	-
MADFIRE [6]	Image classification	Fire persistence	-
Slow-Fast [6]	Image classification	3D-CNN	-
State Key Lab [6]	Image classification	Transformer	-
lplab@Unica [43]	Image classification	Fire persistence	-
Cheng et al. [44]	Image classification	GRU	-
AI-KP [6]	Fire localization	Fire persistence	-
De Venancio et al. [36]	Fire localization	Fire persistence	-
FireBusters [6]	Fire localization	Fire persistence	-
FLAME [41]	Fire localization	Motion analysis and fire persistence	-
FIRE-TASTIC [9]	Fire localization	Motion analysis and fire persistence	Zero-shot classification
FOCUS [35]	Fire localization	Motion analysis and fire persistence	Zero-shot classification

该模型采用基于 MobileNet-v2、EfficientNet-B0 和 ResNet-50构建的三层图像分类器级联结构。对于简单输入图像，首个分类器在置信度超过预设阈值时即输出预测结果，从而最大限度降低计算量；对于复杂场景，则依次调用后续分类器直至获得足够可靠的决策。这种设计可根据图像复杂度动态分配计算资源。该模型仅使用 ONFIRE 训练集进行训练，未采用任何额外的数据增强或外部样本。文献[34]中提出的方法引入了一种基于 ShuffleNetV2的轻量级卷积神经网络模型。该模型虽源自经典架构，但经过大幅简化以降低计算成本同时保持预测精度。该模型既可用于全帧二值分类任务，也可通过SLIC超像素分割技术实现高级火灾定位——每个分割区域均可独立判定为火灾或非火灾状态。由于这些方法仅作用于图像层面而未明确定位火灾区域，在火焰或烟雾仅占据画面小部分（如远距离场景）时会面临识别困难；同样地，当动态场景中出现视觉特征相似的干扰物时，这些方法的可靠性也明显不足。基于目标检测器的方法则具备明确定位图像中火灾/烟雾区域（包括微小或远处实例）的优势，但需依赖包含精确边界框标注的完整训练数据集，导致数据准备工作难度显著增加。Tendeiro提出的方案[7]采用YOLOv8n这一轻量级目标检测器，旨在平衡检测速度与精度要求。

该模型首先对火焰和烟雾实例标注边界框后，在 ONFIRE 训练集上进行精度优化与微调。通过联合损失函数（涵盖目标识别、分类和定位三个维度）对模型进行优化，并采用数据增强技术提升模型在不同监控环境下的鲁棒性。推理阶段以每秒1帧的速率采集图像帧并输入检测器，当检测到火焰或烟雾且置信度超过阈值时即触发警报。文献[35]中描述的YOLOv5s、YOLOv8s、YOLOv11s及YOLOv12s检测器均基于聚焦数据集训练，该数据集经过精心采集与整理，正是这些方法的核心优势所在。由于检测性能与训练数据的质量及多样性密切相关，该数据集包含海量、多样且均衡分布的火焰、烟雾样本以及具有挑战性的非火灾样本，涵盖 ONFIRE 训练集提取帧、D-Fire数据集的大部分图像以及从网络和公开数据源获取的三万余张额外图像。研究特别注重确保数据在距离范围、光照条件、天气变化及地理环境方面具有多样性，尤其重视纳入包含火焰类物体的复杂阴性样本。由此构建的数据集具有较高的阴性样本比例，并且火焰与烟雾标注数量均衡，为系统的灵敏度和鲁棒性提供了有力保障。

如我们在第V节中所示，这些方法获得的F值有限（低于85%），主要原因是剔除假阳性结果时精确度不足：最佳情况下约为75%，平均情况下约为60%。

B. 空间与时间分析

在本节中，我们介绍了结合空间与时间信息进行火灾检测的方法：利用帧序列验证火焰或烟雾的持续存在，并捕捉火灾特征信号的典型运动模式。这些方法通过融入时间推理机制超越了单帧图像分析，有助于降低误报率，从而提升实际监控场景中的检测精度。这些方法可根据用于检测单帧图像火灾的策略（从图像分类到火灾定位）以及评估连续帧间时间一致性与运动动态的具体技术进行区分。在基于图像分类的方法中，KIOS-EVAI方法[6]采用改进版EfficientNet-B0分类器并添加CBAM注意力模块，实现了基于帧级的火灾检测，该模块能更精准地聚焦与火灾相关的空间特征和通道特征。该模型在扩展版的ONFIRE数据集上进行训练，该数据集通过添加额外的私有森林火灾视频进行了扩充——以每秒1帧的采样率获取的数据可生成超过12万帧带标签图像。时间一致性通过滑动窗口策略实现：系统计算视频一秒钟内的平均分类置信度，仅当该综合评分超过预设阈值时才会触发火灾警报。42 firestart方法采用基于MobileViTv2的分类器，在帧级层面检测火灾，该分类器可判断每帧图像属于着火前或着火后时间段。完成初步分类后，该方法会执行时间后处理步骤，通过分析滑动窗口内置置信度分数的变化趋势来精确定位起火时刻并降低报警延迟。网络训练使用经过数据增强（包括翻转、旋转和随机裁剪）处理后的ONFIRE数据集。Madfire方法[6]采用改进版ResNet-50分类器逐帧检测火灾，该模型额外增加了九个全连接层（其中八个使用ReLU激活函数、一个为Sigmoid输出层）以及多个丢弃层以提升泛化能力。该模型在扩展数据集上训练，该数据集通过整合其他来源的火灾影像补充了ONFIRE数据集。为确保时间一致性，系统要求连续5帧均检测到火灾后才会发出最终警报。Slow-Fast方法[6]pe采用基于Slow-Fast-R50架构构建的3D-CNN实现空间与时间联合火灾检测。该方法对短视频片段而非单帧图像进行二元分类：慢速路径在低帧率下提取高层次语义特征，而快速路径则捕捉火焰和烟雾特有的快速时序变化特征。原始分类器被替换为单输出Sigmoid层，用于实现视频级别的二元火灾检测。为训练模型，研究人员采用多种增强技术对ONFIRE数据集进行了扩充，包括高斯模糊、水平翻转以及亮度、对比度、色相和饱和度的随机调整，并新增了其他处理方式。

从网络中采集负样本以缓解类别不平衡问题。国家重点实验室[6]提出的方法通过视频Swin变换器（Video SwinT）联合分析空间与时间特征来实现火灾检测。该方法对连续帧组成的短视频片段进行处理，利用移窗自注意力机制使模型能够捕捉在多帧中持续存在或演变的火焰/烟雾模式。特征提取后，采用包含3D最大池化、丢弃层和全连接层的轻量级分类头，在保持计算效率的前提下生成最终判断结果。训练时，研究者使用了富含含正例火灾视频的ONFIRE数据集，从而提升了该方法的灵敏度。Iplab@Unica方法[43]则通过对16帧连续序列进行时序分类来实现火灾检测。首先使用OpenGVLabVideoMAE v2-Base模型对单帧图像进行编码以提取视频嵌入特征，随后这些特征通过基于GPT-2的分类器进行处理——该分类器经过LoRA方法微调，可实现无火灾、火焰或烟雾等事件的多标签预测。时间一致性通过平滑滤波器实现：只有当至少三个连续帧序列均预测存在火灾时，系统才会确认火灾检测结果，从而有效降低误报率并提升事件发生时间的估计精度。Cheng等人[44]提出了一种火灾检测方法：先利用DenseNet卷积网络从单帧图像中提取空间特征，再采用GRU循环模块建模视频片段的时间动态变化。该模型为每个视频片段输出概率评分，而循环GRU结构则隐式捕捉时间一致性特征，使系统能够准确反映火焰或烟雾在连续帧中的持续存在与运动特性。

如前一节所述，仅基于图像分类的方法往往效果较差，尤其在复杂场景中。为解决这些局限性，研究人员开发了多种方法：这些方法依赖于明确的火灾定位技术，并利用经过精心整理、标注有火焰和烟雾边界框的数据集来训练检测器，从而提升其灵敏度与鲁棒性。AI-KP方法[6]采用YOLOv8n单阶段检测器进行帧级火灾检测，该检测器能够识别火灾区域并为每个视频帧输出对应的边界框。该模型在包含67,536张图像的手动标注数据集上训练完成（数据源自ONFIRE数据集并经过数据增强处理）。为确保时间一致性并降低误报率，系统仅在连续至少 N 帧均检测到火灾时才会触发警报，从而验证火焰随时间推移的持续存在性。此外，De Venancio等人提出的方法也值得关注。[36]d利用基于DFIRE数据集训练的YOLOv5目标检测器对单帧图像中的火灾进行检测。时间一致性通过基于规则的分析方法进行评估：该方法不仅验证检测到的火灾在连续30帧图像中的持续存在，同时追踪对应边界框的位置与尺寸，以降低误报率并确认真实火灾事件。

FireBusters方法[6]采用单阶段YOLOv5s检测器进行帧级火源定位，并通过跨连续帧的置信度累积机制验证时间一致性。为构建可靠的训练集，研究者从ONFIRE数据集中的每段视频中提取每秒一帧图像，并人工检查所得图像，剔除近乎重复的样本，保留能提供互补视觉信息的样本。由于初始数据集严重偏向烟雾场景，研究人员通过网络收集额外的纯火焰、纯烟雾、混合火焰与烟雾以及具有挑战性的阴性样本进行扩充，最终获得包含每个火灾实例边界框标注的32,589张图像。时间持续性通过随时间累积YOLOv5s检测置信度来评估：若任意像素在0.5秒窗口内的累计值超过可配置阈值，则触发火灾警报。Flame[41 a]采用模块化设计方法，将帧级火源定位与基于运动的验证相结合，从而实现高召回率和高精确率。第一阶段中，基于YOLOv8的火灾检测器会在每帧图像中分别识别火焰和烟雾，通过训练经过精心筛选的阳性样本集及具有挑战性的阴性样本集来学习独特的外观特征，从而降低误报率。第二阶段采用背景减除技术仅保留移动目标对象，过滤掉静止的类火源物体；同时利用基于模型的运动分析算法（采用检测追踪法）在触发警报前确认移动火源候选对象的持续存在性和运动一致性。

我们可以得出结论：随着火灾定位精度和训练数据代表性不断提高，以及时间验证机制日益完善，结合空间与时间分析的方法其性能表现愈发稳健。通过评估火灾特征信号随时间的持续存在性和运动特性，这些方法能够更准确地区分真实的火灾事件与瞬态噪声，其召回率和精确度均高于单帧检测器。需要指出的是，这些方法的成功程度在很大程度上取决于火灾检测器的有效性（其准确性远高于图像分类任务）以及时间分析能力。如第五节所示，仅最优方法的F值超过85%，其余方法的表现则与单图像分析方法相当。然而，即便是此类最佳方法仍可能受到持续存在的类火物体的影响——如图2所示，这类物体偶尔会被误判为火灾事件，这凸显了在空间识别能力方面仍需进一步优化。

C. 由视觉-语言模型支持

在本节中，我们介绍了两种近期提出的方法，这些方法整合了视觉-语言模型以支持或验证火灾检测。这些方法背后的原理在于此类模型所经历的大规模图像-文本匹配预训练过程：它们已接触过数百万条标注数据。

对于图像-文本对，系统期望其能够深入理解视觉概念的语义含义，包括识别类火物体并将其与真实火灾区分开来。FIRE-TASTIC [9]结合了任务专用的火灾检测器与通用视觉语言模型以提升可靠性：首先使用YOLOv8s检测器逐帧识别火焰和烟雾，并为潜在火灾区域生成边界框及置信度评分；通过仅标记持续存在火灾候选区域的帧来确保时间一致性，从而减少对计算成本较高的视觉语言模型的调用频率；当检测到火灾候选区域的置信度阈值高于0.4时，系统会请求预训练的BLIP-2模型对检测结果进行验证或拒绝。BLIP-2通过在生成的字幕中识别关键词来确认或排除火灾：若训练时选定的词汇（例如“燃烧”、“烧毁”、“燃烧中”、“燃烧”、“火”、“火焰”、“火焰群”、“点燃”、“烟雾”、“吸烟”）出现在字幕中，VLM便会确认存在火灾。仅当检测器与视觉语言模型达成一致时才会触发火灾警报，这显著降低了误报率同时保持了高召回率。focus[35]e通过根据[5]中定义的分类体系，将火灾检测流程适配至被监控环境的典型视觉条件并考虑距离和背景活动的变化，从而充分利用场景知识。单帧图像中的火焰与烟雾采用基于YOLOv8的二分类目标检测器进行识别，其网络架构经过优化以区分这两种现象。该训练模型基于一个经过精心构建的大型焦点数据集，该数据集包含ONFIRE、D-FIRE以及数千张从网络采集的额外图像，这些图像均经过筛选以最大化正样本的多样性及困难负样本的比例。针对长距离或高活跃度场景，系统通过特定规则验证时间一致性：这些规则持续追踪检测结果的持久性与稳定性，并监测其在连续帧中的置信度、位置及尺寸变化，从而抑制瞬时误报。对于通过短距离高活跃度场景时间过滤的帧，系统采用与FIRE-TASTIC相同的处理方法，调用BLIP-2视觉-语言模型，并以检测到的边界框作为空间提示，从语义层面确认目标区域是否确实存在火灾或烟雾。针对具体操作场景选择最优配置方案，可同时提升召回率和精确率。

如第五节所示，这一系列方法能够实现高于94%的F值，这得益于其有效应对多种复杂场景的能力；其中最佳方法更实现了超过98%的卓越精确率，充分展现了此类方法在实际火灾检测视频监控中的应用潜力。

四、实验框架

在以下章节中，我们将阐述用于评估所研究方法性能的实验框架。



图2.未通过视觉-语言模型进行语义确认的方法所产生的误分类示例。第一行展示了由烟雾状区域被错误识别为火灾所导致的误报；第二行则说明了强光源或火焰形状物体引发误判火焰检测的情况。

火灾检测方法。我们首先阐述用于评估的测试集，重点说明其特性及所面临的挑战；随后详细介绍用于比较火灾检测结果的各项评估指标。

A. 数据集

本实验研究基于两个独立的数据集，二者均旨在评估视频监控系统中的实时火灾检测性能。

第一个数据集是 ONFIRE 竞赛中使用的视频片段集合[7, [8].该数据集包含214个视频片段，其中火灾场景序列与非火灾场景序列各占107个，从而确保在漏检率和误报率方面实现均衡评估。每段正向视频均记录单一火灾事件，火焰首次显现的具体时间点均已人工标注。这些 ONFIRE 视频涵盖了多种采集条件：分辨率（ 320×180 and 1920×1080 ）、时长（10秒至30分钟）、帧率（5至30帧/秒）、光照环境、摄像机与目标间距、场景活动情况以及整体环境复杂度均存在显著差异。这种多样性使得该数据集具有独特的研究价值。

对自动化检测系统提出了更高要求。此外，许多视频片段中存在可能在视觉上类似于火灾或烟雾的元素（如车头灯、反光表面、移动旗帜、雾气或云层结构），这给判别算法带来了额外挑战。为实现场景相关的性能分析，每段视频均被归入[5]中提出的四种类别之一：低活动短距离（LA-SR）、低活动长距离（LA-LR）、高活动短距离（HA-SR）以及高活动长距离（HA-LR）。该分类体系涵盖了场景运动与摄像机距离方面的差异，这些因素已被证实会显著影响火焰和烟雾的视觉呈现效果。ONFIRE 视频片段中相当一部分属于高活动度场景——大量移动物体使得检测复杂化；其余片段则对应控制更严格的低活动度环境。具体而言，已收集到60段背景活动水平较低的视频（其中49段为短距离场景，11段为长距离场景），而其余154段则呈现高活动度的复杂场景（72段为短距离场景，82段为长距离场景）。

评估中使用的第二个数据集为 firetastic[9]，包含156个网络来源的视频，同样均分为78个火灾样本和78个非火灾样本，并与 ONFIRE 类似标注了引燃起始时间。

该数据集中的序列在分辨率（ 320×256 and 1920×1080 之间）、时长（15秒至15分钟不等）、帧率（每秒1至30帧）、光照条件、天气状况及背景运动等方面均存在显著差异。与 ONFIRE 不同，FIRE- TASTIC 标注并未明确划分这四种场景类型，但作者指出该数据集中包含大量远距离场景，这些场景通常以小型或部分被遮挡的火焰区域为特征。因此，该数据集拓宽了视觉场景的多样性，并为评估模型泛化能力提供了补充性基准。

ONFIRE 与 FIRE- TASTIC 数据集共同构成了一个全面且极具挑战性的测试平台，涵盖了从简单的近场场景到复杂、动态且远距离的多种真实环境条件。

B. 评估指标

该评估基于 ONFIRE 竞赛[8]中定义的指标： p 精确率（ P ）、召回率（ R ）、 F 值（ F ）以及火灾检测得分（ FDS ）。为计算这些指标，定义了三组数据：真阳性（ TP ）、假阳性（ FP ）和假阴性（ FN ）。

对于每个视频，火灾点燃时间 g 对应由人工观察者标注的火灾首次可见帧。随后将算法检测时间 p 与此参考值进行比较。若检测结果不早于点燃前五秒发生（ $p \geq \max(0, g - 5)$ ），则判定为正确检测（ TP ）。该容差设定并非必要，因为任何方法都不可能提前预判火灾通知与点燃起始时间的关系。不过赛事组织方仍考虑了此容差值，以避免对各方法造成过度惩罚。所有研究方法的作者均报告了根据该方案计算得出的结果。假阳性可分为两种类型： FP_n （即在阴性视频中检测到的误报，称为正常假阳性）； FPe （即在阳性视频中过早检测到的误报，属于早期假阳性，满足 $p < \max(0, g - 5)$ ）。假阴性（ FN ）则包括所有未触发警报的阳性视频。

随后，精确率与召回率定义如下：

$$P = \frac{|TP|}{|TP| + |FP_n| + |FPe|} \quad (1)$$

$$R = \frac{|TP|}{|TP| + |FN| + |FPe|} \quad (2)$$

其中 $|TP|$ 、 $|FP_n|$ 、 $|FPe|$ 和 $|FN|$ 分别表示真阳性数、正常假阳性数、早期假阳性数和假阴性数。精确率 $P \in [0,1]$ 表示系统避免误报的能力，而召回率 $R \in [0,1]$ 则衡量其正确识别真实火灾事件的能力。

F 值提供了一种能够平衡精确率与召回率的单一评估指标：

$$F = \frac{2 \cdot P \cdot R}{P + R} \quad (3)$$

表 2. 在 ONFIRE 测试集上，各项指标（精确率 P 、召回率 R 、 F 值 F 及火灾检测分数 FDS ）的整体表现。这些方法根据分类标准分为三类：基于单图像分析的方法、基于空间与时间分析的方法，以及依托视觉语言模型的方法。各指标的最佳值均以粗体标出，且方法按其类别内的 F 值降序排列。

Method	P	R	F	FDS
Supported by vision-language models				
FOCUS [35]	98.08	95.53	96.68	0.671
FIRE-TASTIC [9]	96.12	92.52	94.29	0.684
Spatial and temporal analysis				
FLAME [41]	93.20	94.12	93.66	0.743
Firebusters [6]	81.15	98.02	88.79	0.731
Slow-Fast [6]	77.48	87.36	82.12	0.549
De Venancio et al. [36]	61.64	88.24	72.58	0.509
MadFire [6]	51.30	88.76	65.02	0.428
Cheng et al. [44]	42.58	87.25	57.23	0.372
Iplab@Unica [43]	41.57	67.65	51.49	0.281
State Key Lab [6]	34.60	96.05	50.87	0.256
AI-KP [6]	45.95	42.50	44.16	0.157
FIRESTART [42]	31.48	53.12	39.53	0.161
KIOS-EVAI [6]	42.55	19.80	27.02	0.047
Single-image analysis				
YOLOv11s [35]	77.02	93.01	84.26	0.659
YOLOv12s [35]	76.61	93.14	84.07	0.658
YOLOv8s [35]	74.42	94.12	83.12	0.647
YOLOv5s [35]	71.93	80.39	75.93	0.430
Tendeiro [7]	40.12	65.69	49.81	0.264
Int. System Lab [33]	28.64	96.72	44.19	0.270
ShuffleNetV2 [34]	69.57	29.91	41.83	0.133
KutnalNet [26]	43.21	32.71	37.23	0.000
FireNet [32]	53.33	14.95	23.36	0.045

尽管 P 、 R 和 F 被广泛用于评估检测精度，但它们未能充分反映与实时火灾检测相关的实际因素（如响应时间及计算成本）。因此，火灾检测评分（ FDS ）将检测精度、及时性及效率整合为单一评估指标：

$$FDS = \frac{P \cdot R \cdot D_n}{(1 + PFR_\delta) \cdot (1 + MEM_\delta)} \quad (4)$$

其中 D_n 为归一化的平均检测延迟（以最大值60秒为基准）， PFR_δ 表示处理帧率的相对偏差（以10 fps为参考值）， MEM_δ 代表归一化的GPU内存使用量（以4 GB为基准值）。后两项指标用于惩罚推理过程中需要过多计算资源的方法。

V. 结果

在后续章节中，我们将对所有研究方法进行全面评估。首先，我们从整体指标和基于具体场景的详细分析两方面，阐述这些方法在 ONFIRE 测试集上的表现；随后，我们展示其在 FIRE- TASTIC 测试集上的结果，这些结果不仅进一步验证了 ONFIRE 测试中的趋势，还深入揭示了最具竞争力系统的鲁棒性特征。

A. ONFIRE 测试集

对表2中报告的 ONFIRE 测试集实验结果分析表明其性能表现显著。

所评估方法之间的差异反映了基于视频的火灾检测中三个主要因素的重要性：(i)检测器的质量及训练流程；(ii)具备明确的时间分析能力；(iii)能够利用视觉语言模型（VLMs）区分火焰与类火焰物体。

在所有研究方法中，那些将训练有素的检测器与时序分析及视觉-语言模型相结合的方法（即focus和FIRE-TASTIC）展现出最稳健可靠的性能。其优势在于能够适应多种复杂场景，包括测试集中常见的困难情况：动态背景、火焰状干扰物以及存在微小火焰或烟雾区域的远距离场景。这些方法获得的 FDS 值高于仅基于单图像分析的方法，充分体现了准确率、通知延迟与处理资源之间的良性平衡。其中，focus方法凭借其明确的场景适配策略尤为突出。通过根据观测场景的活动强度和距离调整推理流程，Focus系统能够适应不同的应用场景。这种针对性适配不仅实现了极高的精确度（表明其对误报具有强抗性），同时保持了出色的召回率（证明该系统极少漏检真实火灾事件）。虽然FIRE-TASTIC在召回率和精确度方面稍逊于Focus，但得益于其集成VLM模块的互补优势——该模块能在复杂场景中实现语义消歧，从而显著提升系统的整体性能，并使其精确度超越其他方法。

第二层级的方法（包括Flame、FireBusters和Slow-Fast）主要依赖经过专门训练的检测器与明确的时间推理机制相结合。与纯基于检测器的方法相比，这些方法能更好地保证时间一致性，并能够有效抑制由瞬时检测噪声或零星火灾样模式引起的短暂误报。然而，其主要局限在于缺乏高级语义推理能力，这导致其难以可靠地区分视觉特征相似的干扰物（尤其是在高活跃度或远距离场景中）。在该组方法中，Flame凭借基于背景减除与目标追踪的精细时空滤波技术，相较于FireBusters和Slow-Fast实现了显著提升的精确率；这些机制能有效抑制大量误报（即使在复杂背景下亦然），且该方法具有最高的 FDS 值，表明其通知延迟和处理效率均较低。FireBusters虽保持最高召回率和第二佳 FDS 值，但其检测器对类火光图案极为敏感——这种特性有助于捕捉早期或细微的火焰区域，但也增加了误报风险。Slow-Fast得益于强大的时空特征框架，但其召回率与精确率之间的平衡仍不及Flame和FireBusters这类针对性更强的方法，这主要源于区分快速移动物体与火焰时存在的困难。

非燃烧性元素。总体而言，这些中等复杂度的方法表明，仅凭时间推理即可显著提升性能；但若缺乏实现深度语义理解的机制，则在最具挑战性的场景中仍表现不足。

在排行榜中位于这些方法下方的是仅依赖检测器的方法（如YOLOv8、YOLOv11和YOLOv12），其性能反映了单纯依靠空间检测而缺乏时间或语义细化处理的局限性。这些方法能实现较高的召回率——这主要得益于其在异构数据集上的训练（可呈现多样化的火焰纹理与形状）；同时凭借高效性获得了良好的 FDS 值。然而其精确度相对较低，因为单帧图像中检测到的任何类火区域都可能触发警报。若缺乏时间聚合处理，短暂出现的检测噪声、高亮度物体或移动光源常会导致误报。尽管现代基于YOLO的架构具备出色的运算速度和图像级精度，但分析表明仅依赖逐帧预测不足以满足动态环境中稳健的实时火灾检测需求。

排行榜中其余方法普遍存在两大主要问题：(1)相对于有限的数据集规模，模型过于复杂（这也会降低 FDS 值）；(2)基于小型或非代表性数据集训练的单图像分析方法。第一类方法通常基于大型时空架构或复杂的特征融合技术，往往过度依赖训练数据集进行特化训练。因此，这类方法虽然偶尔能实现较高的召回率（即检测出大量真实火灾事件），但常出现低精确率问题——将移动物体误判为火灾。这种现象源于训练数据的偏见：在许多视频片段中，火焰或烟雾像素是唯一的运动特征。导致模型错误地建立运动与火灾存在的不可靠关联，在高活跃场景中产生系统性误差。第二类方法则同时缺乏时间序列分析能力和足够多样化的训练数据集。其结果表现为：由于对常见火灾干扰物的误分类导致精确率偏低；由于缺乏对不同火焰形态、尺寸及距离的充分接触，召回率也较低。这种组合会导致性能不稳定，使其不适用于实际火灾检测系统的部署。

B. 基于情景的分析

表3中报告的特定场景评估结果进一步强化并更清晰地揭示了整体 ONFIRE 结果中观察到的趋势。通过分析四个类别（LA-SR、LA-LR、HA-LR、HA-SR）的表现，可以清楚地看出在检测器质量、时间分析以及 VLM 存在与否等方面的不同架构选择如何影响系统在不同视觉和上下文条件下的鲁棒性。

在所有方法中，聚焦法始终展现出卓越的适应性。除LA-LR场景外，其在所有场景中均获得最高的F值，而LA-LR场景中的表现位列第二。

表3.基于情景分析的 ONFIRE 测试集结果（按以下指标划分）
F值(F)。这些方法根据分类学标准分为三类：基于单图像分析的方法、基于空间与时间分析的方法，以及依托视觉-语言模型的方法。各指标的最佳值均以粗体标出，同时各方法按其类别内的F值降序排列。

Method	LA-SR	LA-LR	HA-LR	HA-SR	Tot
Supported by vision-language models					
FOCUS [35]	100.00	66.67	96.00	94.74	96.68
FIRE-TASTIC [9]	98.67	66.67	79.37	94.44	94.29
Spatial and temporal analysis					
FLAME [41]	98.67	66.67	96.00	91.23	93.66
Firebusters [6]	93.83	80.00	87.18	80.00	88.79
Slow-Fast [6]	98.70	66.67	72.00	66.67	82.12
MadFire [6]	87.50	44.44	63.16	31.17	65.02
Cheng et al. [44]	84.44	40.00	48.21	46.46	57.23
Iplab@Unica [43]	82.76	66.67	48.89	23.81	51.49
State Key Lab [6]	82.76	30.77	35.00	28.57	50.87
AI-KP [6]	31.11	0.00	29.33	54.24	44.16
KIOS-EVAI [6]	34.04	0.00	35.09	6.90	27.02
Single-image analysis					
YOLOv8s [35]	100.00	50.00	85.37	67.61	83.12
Tendeiro [7]	82.35	66.67	51.69	18.18	49.81
Int. System Lab [33]	78.57	36.36	27.12	16.00	44.19
FIRESTART [42]	63.01	20.00	34.00	24.10	39.53
KutalNet [26]	74.63	0.00	8.82	29.17	37.23
FireNet [32]	30.43	0.00	8.89	31.82	23.36

这一结果仅适用于FireBusters方法。该结论与先前讨论的两种方法的特点完全吻合：FireBusters对微弱或遥远的火灾信号具有极强的敏感性，这使其在低活动度、远距离监测场景中占据优势；然而，在动态变化较大的场景中，这种敏感性反而成为劣势。相比之下，focus方法通过基于场景的自适应策略，能为不同情境选择最合适的推理配置。在LA-SR场景中，focus凭借其经过充分训练的检测器所具备的高度灵敏度，在不牺牲精确率的前提下实现了最佳召回率。在长距离场景（LA-LR和HA-LR）中，该方法通过整合时空细化机制，在灵敏度与特异性之间实现了稳定的平衡，有效抑制了由小型移动干扰物或背景动态引起的误检。在具有挑战性的HA-SR场景下，基于VLM的确认步骤起着核心作用：它通过过滤复杂的火状目标显著提升检测精度，从而在所有方法中表现最佳。

研究结果还证实，仅采用火源定位方法时，其性能在LA-SR场景中表现尤为突出——该场景中的火灾区域通常面积更大、距离相机更近，且不易与动态背景元素混淆。在此条件下，这些模型基于异构数据集训练而成的强效空间检测器能够实现较高的召回率和中等精度。然而，在长距离或高活动场景中，其性能显著下降，因为单帧图像预测已无法有效区分真实火灾与零星出现或快速移动的干扰物。由于缺乏时间过滤机制，这些方法特别容易产生假阳性结果，并且在最简单场景之外通常会导致较低的F值。相比之下，将经过充分训练的检测器与显式时间推理相结合的方法（如Flame和FireBusters）在长距离场景中展现出明显优势。时间聚合技术使这些方法更具优势。

这些系统旨在克服火焰可见度降低以及运动伪影（这是HALR场景的典型特征）带来的影响。尤其是火焰检测方面，充分体现了精细时空滤波技术的优势：背景减除与目标追踪相结合的方法相较于其他方法显著提升了检测精度。FireBusters尽管更容易产生误报，但仍能保持较高的召回率，尤其在存在早期或细微火焰区域时。然而，在高分辨率图像处理领域（HA-SR），这两种方法均面临挑战——此时高级语义推理变得至关重要。在此类场景中，唯有配备VLM模块（即focus和FIRE-TASTIC）的方法才能可靠地区分火焰与复杂干扰物（如车头灯、反射影像或快速移动的非火焰物体）。

最后，排行榜中其余方法通常仅在LA-SR场景下能取得满意效果。这些方法在长距离或高活跃度场景中的表现会显著下降，主要原因有两点：首先，相对于有限训练数据而言过于复杂的架构容易过度拟合特定视觉模式，导致跨场景泛化能力不稳定；其次，基于单图像分析且使用小规模或非代表性数据集训练的简单图像分类或检测系统，既缺乏处理模糊或复杂场景所需的时间连贯性，也缺乏语义丰富性。因此，这些方法在不同场景下的表现差异很大，这主要反映了其训练数据集中样本分布的特点，而非真正的鲁棒性。

还需指出的是，这种基于场景的分析清晰地表明：随着场景复杂度的增加，火灾检测难度会逐步上升。尽管大多数方法在低活动度、短距离条件下都能取得令人满意的性能，但其鲁棒性在长距离场景（尤其是高活动度场景）中会显著下降——此时动态背景和类似火焰的干扰因素占据主导地位。这些结果证实，在复杂环境中，简单的空间检测或粗略的时间聚合分析已不再足够。相反，需要采用日益复杂的过滤策略：从基于运动感知的时序验证，到场景自适应处理流程以及语义确认机制，才能在保持检测灵敏度的同时有效抑制误报。这一趋势凸显了将精准的火源定位与先进的时序分析及语义推理相结合的重要性，从而确保在真实监控环境中实现可靠运行。

C. 点火测试套装

尽管表4中报告的FIRE-TASTIC测试集结果仅针对部分方法（即Focus、FIRE-TASTIC、FireBusters和YOLOv8s）有效，但仍进一步证实了所有先前观察结果。

再次证明，焦点算法在所有评估指标中均表现最佳，充分展现了其对多变现实环境的强适应性。FIRE-TASTIC位列第二，在精确率上仅略逊于焦点算法，但在召回率上优势显著，凸显了情境感知能力的重要性。

表4.与在FIRE- TASTIC 数据集上测试的方法相比，各项指标（精确率P、召回率R及F值F）的对比结果。这些方法根据分类标准分为利用单图像分析、空间与时间分析以及基于视觉语言模型的方法三类。各指标的最佳值均以粗体标出，且方法按其类别内的F值降序排列。

Method	P	R	F
Supported by vision-language models			
FOCUS [35]	98.74	97.43	98.08
FIRE-TASTIC [9]	98.57	94.52	96.50
Spatial and temporal analysis			
Firebusters [6]	85.33	87.67	86.49
Single-image analysis			
YOLOv8s [35]	73.91	93.15	82.42

该模型通过适应性调整提升了对细微或远距离火灾事件的检测灵敏度。FireBusters的性能比FIRE- TASTIC 低超过10个百分点，这进一步证明：在环境异质性更高、预测性更强的情况下，视觉-语言模型提供的语义验证对于确保系统鲁棒性及抑制误报至关重要。而缺乏时间推理能力和 VLM 消歧功能的YOLOv8s性能则比FireBusters低4个百分点。这种性能差距进一步凸显了时间分析在降低对瞬态或火灾样干扰因素敏感性方面的重要性，因为仅依赖检测器的方法在FIRE- TASTIC 数据集所呈现的多样化动态条件下评估时，仍易受到虚假响应的影响。

六、讨论与可能的研究方向

对 ONFIRE 和FIRE- TASTIC 测试集的实验评估揭示了一系列连贯的趋势，这些趋势清晰展现了当前基于视频的火灾检测方法的优势与局限。尽管架构范式多样——从仅依赖检测器的基础模型到整合时间分析与视觉-语言模型的系统——但若干关键因素始终是决定系统稳健性能及未来研究价值的核心要素。

A. 结合空间检测、时间分析与语义消歧

最可靠的系统需整合三种互补组件：高性能火灾探测器、明确的时间建模机制以及基于视觉-语言模型的语义推理能力。这些方法在多种视觉条件下均能保持持续较高的精度和召回率，涵盖从短距离低活动场景到长距离或高活动场景（其中火源线索可能变得模糊或被视觉干扰所掩盖）等多种情况。其优越性源于三个要素的协同作用：空间检测器可灵敏识别火焰与烟雾模式；时间分析可降低短暂虚假激活的影响；基于 VLM 的确认机制则能消除干扰因素下产生的语义歧义。研究结果表明，这一三要素组合目前构成了构建稳健系统的最有效设计范式。

具备实际应用能力的火灾检测系统。为进一步提升此类技术方案的水平，未来研究方向可考虑开发轻量级实时 VLM 组件，采用 PEFT 重参数化、LoRA类适配器或提示优化策略，使语义验证既高效又能在嵌入式硬件上实现部署。此外，系统可根据场景特性在运行时自动调整检测器阈值、时间窗口或 VLM 使用方式，实现动态管道适配。最后，联合空间-时间-语义训练可使检测器学习具有上下文感知能力的表征，而非依赖于跨组件优化能力有限的独立模块。

B. 情景适应

实验结果明确表明，基于场景感知的方法——即模型能根据预估的场景特征动态调整推理策略——展现出巨大潜力。这种自适应机制通过灵活调整检测器灵敏度、时间滤波参数及语义验证规则以适配任务需求，从而同时提升召回率与精确率。这一自适应火灾检测原理成为实验中最引人注目的发现之一，为该领域的发展指明了前景广阔的方向。现有方法未来可能的改进方向包括集成自动场景分类模块，使其能够实时识别场景类型、摄像机运动状态、环境条件及距离类别。此外，一种可行的方向是构建统一框架，将场景估计、检测、时序过滤和语义确认紧密整合到端到端处理流程中。作为替代方案，可设计元学习策略，使检测模型在遇到未知场景时能够快速调整其内部参数。

C. 时间分析

能够进行有效时间分析的方法相较于其他方法具有明显优势，尤其在处理长距离场景或动态背景环境时更为显著。时间聚合技术有助于弥补火灾区域范围小或出现间歇性的情况，稳定预测结果，并降低误报率（如闪烁警报）。然而，由于缺乏语义推理能力，现有方法在应对干扰因素与火灾外观或运动模式高度相似的场景时存在局限。尽管这些系统具有较高的召回率和良好的鲁棒性，但在面对视觉复杂或高度动态的环境时，其识别精度往往趋于停滞。为更好地克服这些局限性，设计能够根据场景复杂度、运动幅度或火源区域估计距离来调节灵敏度的自适应时序滤波器，有助于在时序过滤呈现不确定性或模糊性时选择性激活 VLM 确认机制。此外，采用基于变换器或扩散网络启发式结构的时序骨干网络，可在不增加过高计算成本的前提下学习长时程时间依赖关系。

D. 需要大规模、情景平衡且逼真的视频数据集

在两个测试集上反复出现的一个核心主题是训练数据多样性的影响。基于有限或不平衡数据集训练的模型，其性能会因训练场景与测试场景之间的相似度而呈现差异：长距离视频和高活跃度场景在现有数据集中仍缺乏充分样本，这限制了许多方法的泛化能力；此外，部分方法由于架构复杂度相对于可用数据集的规模和多样性而言过高而表现欠佳——这些系统往往会对训练过程中出现的具体时空模式产生过拟合，导致在不同场景下表现不稳定；相反，仅使用简单检测器并在有限数据集上训练的系统则缺乏实现对未知场景泛化的视觉经验广度。基于有限或不平衡数据集训练的模型，其性能会因训练场景与测试场景之间的相似性差异而有所不同。为解决这些问题，开发涵盖关键场景（LA-SR、LA-LR、HALR、HA-SR）且具有均衡样本分布的新火灾检测数据集（理想情况下应包含真实环境中的数百小时视频片段），将显著提升火灾检测方法的性能。此外，还需推进数据集标准化工作，确保未来的评估基准在活动强度、距离、光照条件及干扰物类型等关键维度均具备均衡样本覆盖。同时，科学界可制定强调领域泛化的评估标准，促使检测方法在数据分布变化时仍能保持良好性能，而不仅限于训练期间遇到的特定场景。

E. 持续学习与领域适应

观察结果（尤其是现有数据集）所提示的一个尤为重要的方向，涉及持续学习框架与领域适应框架的整合。实验分析明确表明，现有系统（尤其是缺乏语义推理或显式场景适应能力的系统）在应用于与其训练集所涵盖的有限场景不同的环境时会遇到困难。这一问题在过度拟合特定运动或外观模式的方法中尤为明显，同样也存在于仅使用小规模或有偏见数据集训练的检测模型中。这些局限性凸显了开发能够随着新视觉条件、摄像机视角、环境背景或火灾/非火灾干扰因素类型的变化而逐步更新内部表征的方法的必要性。因此，未来研究可重点探索专为视频火灾检测设计的持续学习策略——这类策略能使模型随时间推移不断整合新的示例视频或场景类型，从而提升模型鲁棒性而无需从头重新训练。最关键的是，这些方法必须避免

灾难性遗忘，即在学习新场景时，对先前已掌握场景的表现能力出现下降。与此同时，领域适应框架为持续学习提供了重要的补充。鉴于火灾检测系统可能部署在与现有数据集所涵盖环境（工业场景、森林、城市环境等）截然不同的环境中，跨领域的泛化能力至关重要。领域适应机制能够使系统将源域（训练数据）的特征表示与目标域（实际应用场景）的特征表示相匹配——即使后者中的标注数据稀缺或缺失。此外，更具挑战性的方向或许是结合持续学习与领域适应技术，使系统能够在保持抗遗忘能力的同时，逐步获取针对特定场景的新知识。

七、结论

本研究对实时火灾检测方法进行了全面评估，评估基于目前最广泛的两项视频监控基准数据集——ONFIRE和FIRE-TASTIC测试集。通过分析从基于单图像分析的轻量级检测器，到具备时间感知能力的架构以及整合视觉-语言模型的方法等广泛研究路径，我们系统阐述了火灾检测领域的当前技术水平及其在实际部署中的实践挑战。

基于这项比较研究得出的见解，若干具有前景的研究方向逐渐清晰。核心方向在于空间检测、时间分析与语义消歧的结合。该领域关键在于开发更先进的验证机制，尤其是那些利用高效且可适应性强的视觉-语言模型，并通过PEFT或提示优化等轻量级微调策略进行增强的模型。此外，针对具体应用场景进行适配以及制定更先进的时间分析方法，将进一步提升系统性能，尤其在长距离和高活跃度场景下效果更为显著。具备持续学习能力和领域适应能力的方法——使模型能够在处理新数据时不断进化，同时避免灾难性遗忘——是实现动态环境中长期可靠性的关键步骤。此外，开发更均衡、多样化的数据集（准确反映包括远距离监控、高活跃度场景以及类似火灾干扰场景在内的各种真实监控环境）也至关重要。总之，这类能够实现持续学习与领域适应、让模型随新数据演进并防止灾难性遗忘的方法，正是构建动态环境中长期可靠性的核心要素。

通过这项工作，我们不仅对现有的实时火灾检测方法进行了评估，还为未来旨在开发更高效、更具适应性且具备情境感知能力的火灾检测系统的研究方向制定了路线图。

适用于部署于日益复杂的现实场景中的技术。

ACKNOWLEDGMENT

作者们衷心感谢A.I. Tech srl（意大利）提供的宝贵支持，并就实时视频监控领域提出富有见地的建议，这些建议对本研究的开展作出了重要贡献。（所有作者均对本研究贡献相同。）

参考文献

- [1] C. A. Akdis and K. C. Nadeau, 《人类与行星健康面临严峻挑战》，《自然·免疫学》，第22卷，第11期，第651–652页，2022年11月。
- [2] K. R. van Daalen 等人，《《柳叶刀》健康与气候变化倒计时报告：2024年欧洲报告——前所未有的气候变暖需要前所未有的行动》，《柳叶刀·公共卫生》，第9卷第7期，第e495–e522页，2024年7月。
- [3] R. H. Nolan, L. Collins, A. Leigh, M. K. J. Ooi, T. J. Curran, T. A. Fairman, V. Resco de Dios and R. Bradstock, 《气候变化下火灾后植被恢复的极限》，《植物与细胞环境》，第44卷，第11期，第3471–3489页，2021年11月。
- [4] J. E. Halofsky, D. L. 彼得森与B.J. 哈维，《野火变迁与森林变迁：气候变化对美国太平洋西北地区火灾模式及植被的影响》，《火灾生态学》，第16卷第1期，第1–26页，2020年12月。
- [5] D. 格拉尼亚尼埃洛、A. 格雷科、C. 桑索内和B. 文托，《基于视频的火灾与烟雾检测：一种新型分类法下的文献综述》，《专家系统应用》，第255卷，2024年12月，文章编号：124783。
- [6] D. 格拉尼亚尼埃洛、A. 格雷科、C. 桑索内和B. 文托，《Onfire 2023竞赛：我们从摄像头实时火灾检测中获得了哪些启示？》J. *Ambient Intelligence. Humanized Computing*, 第16卷，第1期，第253–264页，2025年1月。
- [7] D. 格拉尼亚尼埃洛、A. 格雷科、C. 桑索内和B. 文托，《Onfire竞赛2025：边缘端实时火灾与烟雾检测》，载于《国际图像分析与处理会议论文集》，瑞士尚美：Springer出版社，2025年9月，第561–573页。
- [8] D. 格拉尼亚尼埃洛、A. 格雷科、C. 桑索内和B. 文托，《Onfire竞赛2023：边缘端实时火灾检测》，载于《国际图像分析与处理会议论文集》，2023年，第273–281页。
- [9] D. 格拉尼亚尼埃洛、A. 格雷科、C. 桑索内和B. Vento, 《基于任务感知目标检测器引导的零样本视觉-语言模型视频火灾识别》，*ACM多媒体计算、通信与应用汇刊*，第21卷，第10期，第1–24页，2025年10月。
- [10] W.-B. Horng, J.-W. Peng 和 C.-Y. Chen, 《一种基于颜色分析的新型图像实时火焰检测方法》，载于《IEEE网络传感与控制会议录》，2005年3月，第100–105页。
- [11] T. Celik 和 H. Demirel, 《基于通用颜色模型的视频序列火灾检测》，《火灾安全杂志》，第44卷第2期，第147–158页，2008年。
- [12] 陈天浩 (T.-H. Chen)、吴鹏华 (P.-H. Wu) 与邱永昌 (Y.-C. Chiou), 《基于图像处理的早期火灾检测方法》，载于《国际图像处理会议论文集》，第3卷，2004年，第1707–1710页。
- [13] T. Celik, H. Demirel, H. Ozkaramanli 和 M. Uygurolu, 《基于统计颜色模型的视频序列火灾检测》，J. *Vis. Commun. Image Represent.*, 第18卷，第2期，第176–185页，2007年4月。
- [14] V. 卡莱蒂、A. 格雷科、A. 萨杰塞和B. 文托，《基于深度神经网络的智能烟雾检测视觉传感器》，《传感器》，第24卷，第14期，第4519页，2024年。
- [15] G. 马尔巴赫、M. 洛普费特和T. 布鲁普巴赫，《一种用于视频图像火灾检测的图像处理技术》，《火灾安全杂志》，第41卷第4期，第285–289页，2006年6月。
- [16] P. Foggia, A. Saggese 和 M. Vento, 《基于颜色、形状和运动特征的专家组合技术实现视频监控应用中的实时火灾检测》，*IEEE电路与系统汇刊·视频技术*，第25卷第9期，第1545–1556页，2015年9月。
- [17] 李浩立 (H.-L. Li)、刘世伟 (S.-W. Liu) 和陈世伟 (S.-W. Chen), 《基于偏振卷积分不变特征的PolSAR卫星在不同掠射角下的特性分析与鲁棒检测》，《IEEE地球科学与遥感汇刊》，第62卷，2024年。
- [18] 李海林 (H.-L. Li) 与陈世伟 (S.-W. Chen), 《采用全偏振雷达对
- [19] 李汉立与陈世伟, 《通用偏振相关模式：一种用于研究目标联合域散射机制的可视化与表征工具》，《IEEE地球科学与遥感汇刊》，第64卷，2026年。
- [20] 皮耶蒂凯宁先生、哈迪德女士、赵先生和T先生阿霍宁, 《Computer Vision Using Local Binary Patterns》。瑞士尚美：施普林格出版社，2011年。
- [21] C. E. Prema, S. Suresh, M. N. Krishnan 和 N. Leema, 《一种利用局部二值模式变体共现特征的新型高效视频烟雾检测算法》，《火灾技术》，第58卷第5期，第3139–3165页，2022年9月。
- [22] C. R. Steffens, S. S. D. C. Botelho 和 R. N. Rodrigues, 《基于纹理特征的移动机器人可见光谱火灾检测方法》，载于《拉丁美洲机器人研讨会论文集/巴西机器人研讨会论文集 (LARS/SBR)》，2016年10月，第257–262页。
- [23] 托拉比安 (M. Torabian)、普尔加塞姆 (H. Pourghassem) 与马赫达维·纳萨布 (H. Mahdavi-Nasab), 《基于分形分析与时空特征的火灾检测》，《火灾技术》，第57卷第5期，第2583–2614页，2021年9月。
- [24] K. 穆罕默德、S. 汗、M. 埃尔霍塞尼、S. 哈桑·艾哈迈德和 S. 伍克·拜克, 《不确定监控环境下的高效火灾检测》，*IEEE工业信息学汇刊*，第15卷第5期，第3113–3122页，2019年5月。
- [25] 李思、严强和P.刘, “一种基于多尺度特征提取、隐式深度监督和通道注意力机制的高效火灾检测方法”，*IEEE图像处理汇刊*，第29卷，第8467–8475页，2020年。
- [26] A. 阿亚拉、B. 费尔南德斯、F. 克鲁兹、D. 马塞多、A. L. I. 奥利维拉及C. 扎切廷, 《KutralNet: 一种用于火灾识别的便携式深度学习模型》，载于《国际神经网络联合会议 (IJCNN) 论文集》，2020年7月，第1–8页。
- [27] 尹泽、万斌、袁峰、夏旭和石杰, 《一种用于图像烟雾检测的深度归一化与卷积神经网络》，*IEEE Access*，第5卷，第18429–18438页，2017年。
- [28] 顾凯、夏志、乔杰和林伟, 《基于图像的烟雾检测深度双通道神经网络》，*IEEE多媒体汇刊*，第22卷第2期，第311–323页，2020年2月。
- [29] A. Hosseini, M. Hashemzadeh 和 N. Farajzadeh, 《UFS-Net: 一种基于卷积神经网络的视频监控应用中火灾早期检测的统一火焰与烟雾识别方法》，J. *Comput. Sci.*，第61卷，2022年5月，文章编号：101638。
- [30] D. 沈、J. 邓和 J. 向某, 《基于SLIC-DBSCAN 增强卷积神经网络的自动烟雾检测》，*IEEE Access*，第9卷，第63933–63942页，2021年。
- [31] M. 哈谢姆扎德、N. 法拉杰扎德和M. 海达里, 《利用卷积神经网络与高效时空特征进行视频烟雾检测》，*应用软计算*，第128卷，2022年10月，文章编号：109496。
- [32] A. Jadon, M. Omama, A. Varshney, M. S. Ansari 和 R. Sharma, 《FireNet: 一种专为实时物联网应用设计的轻量级火灾与烟雾检测模型》，2019年，arXiv:1905.11922。
- [33] G. 文森特、L. 德桑蒂斯、E. 帕滕和S. 巴塔查里亚, 《采用早期退出机制的快速火灾检测》，载于《国际图像分析与处理会议论文集》，2023年，第294–301页。
- [34] W. Thomson, N. Bhowmik 和 T. P. Breckon, 《用于非时序实时火灾检测的高效紧凑卷积神经网络架构》，载于《第十九届IEEE国际机器学习应用会议论文集 (ICMLA)》，2020年12月，第136–141页。
- [35] D. 格拉尼亚尼埃洛、A. 格雷科、C. 桑索内与B. 文托, 《聚焦：通过场景适配提升视频火灾检测性能》，《图像视觉与计算》，第162卷，2025年10月，文章编号：105679。
- [36] P. V. A. B. 德·韦南西奥、R. J. 卡姆波斯、T. M. 雷森德、A. C. 利斯博阿和 A. V. 巴尔博萨, 《基于时空模式的火灾检测混合方法》，《神经计算与应用》，第35卷第13期，第9349–9361页，2023年5月。
- [37] 曹宇、唐强、徐帅、李峰和卢旭, 《QuasiVSD: 高效的双帧烟雾检测》，《神经计算应用》，第34卷，第11期，第8539–8550页，2022年6月。

多面体角反射器进行多域联合表征》，*IEEE天线与传播学报*，第73卷第12期，第10679–10693页，2025年12月。

- [38] 沙希德先生、J. J. Virtusio、吴永华、陈永义、Tanveer先生、K. Muhammad及Hua K.-L.，《视频监控中火灾检测与分割的时空自注意力网络》，*IEEE Access*，第10卷，第1259–1275页，2022年。
- [39] 曹宇、杨峰、唐强和卢旭，《一种基于注意力机制的双向 LSTM 用于早期森林火灾烟雾识别》，*IEEE Access*，第7卷，第154732–154742页，2019年。

- [40] A. 德万甘、Y. 潘德、H.-W. 布劳恩、F. 维尔农、I. 佩雷斯、I. 阿尔廷塔斯、G. W. 科特雷尔和 M. H. 阮，《FlgLib与SmokeyNet：用于实时野外森林火灾烟雾检测的数据集与深度学习模型》，*遥感*，第14卷第4期，第1007页，2022年2月。
- [41] D. 格拉尼亚尼埃洛、A. 格雷科、C. 桑索内和B. 文托，《火焰：结合深度神经网络与基于模型的运动分析的视频火灾检测》，《*神经计算应用*》，第37卷第8期，第6181–6197页，2025年3月。
- [42] L. Zedda、A. Loddo 和 C. Di Ruberto，《火源识别：采用增强平滑技术和实时跟踪的火灾点火检测》，载于*Proc. Int. Conf. Image Anal. Process.*，2023年，第282–293页。
- [43] L. Zedda、A. Loddo 和 C. D. Ruberto，《Event-GPT：基于LoRA调优GPT的序列感知视频事件分类》，载于《*国际图像分析与处理会议论文集*》，瑞士尚美：Springer出版社，2025年9月，第574–585页。
- [44] S. Cheng与S. I. Kamata，《基于DenseNet和Transformer的监控系统实时火灾识别方法》，载于*国际会议论文集. Image Anal. 过程*。瑞士尚姆：Springer出版社，2025年9月，第586–594页。
- [45] A. 格雷科、A. 萨杰塞、C. 桑索内和B. 文托，《基于多任务学习与视觉语言模型的行人特征识别智能传感器实验评估》，《*Sensors*》，第25卷第6期，第1736页，2025年3月。

文森佐·卡尔莱蒂（IEEE会员）于2016年同时获得意大利萨莱诺大学计算机工程领域及法国昂西卡恩大学应用计算机科学领域的博士学位，并获欧洲联合认证。其博士论文研究项目荣获“意法大学联盟”（UIF – UFI）

“Vinci Call”计划以及 IAPR 意大利分会颁发的“意大利最佳博士学位”称号（2018年）。现任意大利萨莱诺大学DIEM系副教授，研究方向涵盖图匹配、图神经网络、计算机视觉及网络安全领域的人工智能。2025年起，他担任国际模式识别协会（IAPR）第15届技术委员会主席。



安东尼奥·格雷科（IEEE会员）获得了博士学位。他于2018年毕业于意大利萨莱诺大学，获计算机科学与计算机工程学位。现任萨莱诺大学DIEM研究所副教授。其研究领域涵盖计算机视觉与模式识别，重点致力于利用静态及移动传感器实现实时场景理解。他曾组织多项国际竞赛，并担任《*模式分析与应用*》期刊的副主编，以及多家顶尖计算机视觉期刊特刊的客座编辑。

阿莱西亚·萨杰塞（IEEE会员）于2014年同时获得意大利萨莱诺大学和法国昂西昂大学颁发的带有欧洲认证标识的计算机科学与计算机工程双博士学位。其博士论文研究项目曾荣获“意法大学联盟”（UIF – UFI）Vinci资助计划以及 IAPR 意大利分会颁发的“意大利最佳博士学位奖”，获奖时间跨度为2014年至2016年。她现任DIEM学院副教授，研究领域涵盖计算机视觉与模式识别，重点聚焦认知机器人学及实时场景理解。



布鲁诺·VENTO 目前正在攻读博士学位。他毕业于那不勒斯费德里科二世大学，主攻农业与环境监测领域的人工智能研究。曾任职于A.I. Tech公司担任机器学习工程师，专注于智能视频分析所需的计算机视觉算法开发。其研究方向涵盖火灾、烟雾及垃圾检测，以及行人特征识别与再识别技术。他曾组织过四场国际学术竞赛，并担任《*模式识别*》与《*模式分析与应用*》期刊的客座编辑。



...

